

Ministère de la Communication et de l'Économie Numérique

École Supérieure Africaine des Technologies
de l'Information et de la Communication

Année académique : 2022 – 2023



**MÉMOIRE DE FIN DE CYCLE POUR L'OBTENTION DU MASTER
EN RÉSEAUX ET TÉLÉCOMMUNICATIONS**

**CONCEPTION D'UN SYSTÈME D'AIDE INTÉGRÉ POUR LA DÉTECTION
DU CANCER DU SEIN DANS UN ERP UTILISANT DES RÉSEAUX DE
NEURONES :**

CAS DU DOSSIER PATIENT INFORMATISÉ (DPI)

M-23.DAB.227

Présenté par : **DABONE Souleymane**

Période de stage : Du 08 février au 08 juillet 2023

Encadrants académiques

Maître de stage

Dr YOBOUE Pamela, Maître de conférences, ESATIC

M. TANO Jacob

Dr KONE Kigninman Désiré, Maître-assistant, ESATIC

Data scientist, Responsable technique à TIR

Membres du jury

Dr SORO Adama, Maitre de Conférence, l'université de Cocody, (Président du jury)

Dr BROU Pacôme, Maître-assistant, ESATIC (Rapporteur)

M. NZI KONAN, Ingénieur en Télécommunication (Assesseur)

Mme COULIBALY Mariame, Enseignante, ESATIC (Membre)

Ministère de la Communication et de l'Économie Numérique

École Supérieure Africaine des Technologies
de l'Information et de la Communication

Année académique : 2022 – 2023



MÉMOIRE DE FIN DE CYCLE POUR L'OBTENTION DU MASTER EN RÉSEAUX ET TÉLÉCOMMUNICATIONS

**CONCEPTION D'UN SYSTÈME D'AIDE INTÉGRÉ POUR LA DÉTECTION
DU CANCER DU SEIN DANS UN ERP UTILISANT DES RÉSEAUX DE
NEURONES :
CAS DU DOSSIER PATIENT INFORMATISÉ (DPI)**

M-23.DAB.227

Présenté par : **DABONE Souleymane**

Période de stage : Du 08 février au 08 juillet 2023

Encadrants académiques

Maître de stage

Dr YOBOUE Pamela, Maître de conférences à ESATIC

M. TANO Jacob

Dr KONE Kigninman Désiré, Maître-assistant à ESATIC

Data scientist, Responsable technique à TIR

Membres du jury

Dr SORO Adama, Maitre de Conférence, l'université de Cocody, (Président du jury)

Dr Brou Pacôme, Maître-assistant, ESATIC (Rapporteur)

M. NZI Konan, Ingénieur en Télécommunication (Assesseur)

Mme Coulibaly Mariame, Enseignante, ESATIC (Membre)

DÉDICACE

À ma famille chérie,

Les fondations de mon succès, les gardiens de mes rêves et les rayons de soleil qui ont éclairé chaque étape de mon parcours, je vous dédie ce travail, en témoignage de mon amour et de ma reconnaissance.

RÉMERCIEMENTS

L'élaboration de ce mémoire est le fruit de plusieurs mois de recherches approfondies et d'un stage enrichissant, rendu possible grâce aux précieux conseils, soutiens, encouragements et à la disponibilité de certaines personnes auxquelles nous souhaitons exprimer notre profonde gratitude.

Nous tenons tout d'abord à remercier Prof KONATE Adama, Directeur Général de l'ESATIC, pour le cadre d'études.

Notre gratitude s'étend également à nos encadrants académiques, Dr YOBOUE Pamela et Dr KONE Kigninman Désiré, respectivement maître de conférences et maître-assistant à l'ESATIC, pour leurs critiques constructives et leur soutien. Par ailleurs, nous exprimons notre reconnaissance envers le Directeur Général, M. KONE Zana Noël, qui nous a accueillis au sein de son entreprise et a rendu possible ce stage.

Nous souhaitons aussi exprimer notre profonde reconnaissance à notre maître de stage, M. TANO Jacob, Data scientist et Responsable technique à TIR, pour sa disponibilité à répondre à nos nombreuses questions, sa patience et sa contribution essentielle à notre acquisition de compétences techniques solides.

Nous remercions chaleureusement l'ensemble de l'équipe de TIR pour son accueil chaleureux. Nous ne saurions oublier de remercier tous nos amis qui ont directement ou indirectement participé à la réalisation de ce mémoire.

SOMMAIRE

INTRODUCTION

PRÉMIÈRE PARTIE : GÉNÉRALITÉS

CHAPITRE I : CADRE ET CONTEXTE DE TRAVAIL

- I. Présentation de la structure d'accueil
- II. Étude de l'existant
- III. Cahier des charges

CHAPITRE II : ÉTUDE DU PROJET

- I. Cancer du sein
- II. Réseaux de neurones
- III. État de l'art

DEUXIÈME PARTIE : ÉTUDE TECHNIQUE

CHAPITRE III : CONCEPTION DU MODULE DE VISION PAR ORDINATEUR

- I. Réseaux de neurones convolutifs
- II. Modèle de Vision par ordinateur

CHAPITRE IV : ÉTUDE CONCEPTUELLE DE L'APPLICATION WEB

- I. Choix de la méthode de conception
- II. Identification des acteurs et besoins du système

TROISIÈME PARTIE : RÉSULTATS ET DISCUSSION

CHAPITRE V : RÉSULTATS

- I. Outils de développement
- II. Présentation des résultats

CHAPITRE VI : DISCUSSION DES RÉSULTATS ET COÛT DU PROJET

- I. Discussion des résultats
- II. Coût du projet

CONCLUSION

LISTE DES SIGLES ET ABRÉVIATIONS

2TUP	2 Track Unified Process
API	Application Programming Interface
AUC-ROC	Area Under the Receiver Operating Characteristic
BIRADS	Breast Imaging Reporting and Data System
CBIS-DDSM	Curated Breast Imaging Subset - Digital Database for Screening Mammography
CCIS	Carcinome Canalaire In Situ
CLIS	Carcinome Lobulaire In Situ
CNRAO	Centre National d'Oncologie Médicale et de Radiothérapie Alassane Ouattara
CMMD	Chinese Mammography Database
DICOM	Digital imaging and communications in medicine,
DPI	Dossier Patient Informatisé
ERP	Enterprise resource planning
GAN	Generative Adversarial Networks
GloblocaN	Global Observatory of Cancer
GPU	Graphics Processing Unit
Grad-CAM	Gradient-weighted Class Activation Mapping
IA	Intelligence Artificielle
JPEG	Joint Photographic Experts Group
PNG	Portable Network Graphics
ROI	Region of interest
RNC	Réseaux de Neuronaux Convolutifs
RNSA	Radiological Society of North America
ESATIC	Ecole Supérieure Africaine des Technologies de l'Information et de la Communication
TIR	Technology Innovation Revolutionner
TPU	Tensor Processing Unit
UML	Unified Modeling Language
VO	Vision par Ordinateur

GLOSSAIRE

API

API est l'acronyme d'Application Programming Interface, qui est un intermédiaire logiciel qui permet à deux applications de communiquer entre elles.

Apprentissage automatique

L'apprentissage automatique, également appelé apprentissage machine ou apprentissage artificiel et machine learning en anglais, est une forme d'IA qui permet à un système d'apprendre à partir des données et non à l'aide d'une programmation explicite.

Apprentissage en profondeur

L'apprentissage profond ou le deep learning en anglais est un type d'intelligence artificielle dérivé de l'apprentissage automatique et basé sur des réseaux de neurones artificiel inspiré du fonctionnement du cerveau humain.

ERP médical

L'ERP médical représente une solution logicielle dédiée au secteur de la santé, conçue spécifiquement pour orchestrer les activités et les procédures administratives au sein des établissements médicaux. Il permet de gérer divers aspects, tels que la tenue des dossiers patients, la planification des rendez-vous, la facturation ainsi que la gestion des stocks médicaux.

Intelligence Artificielle (IA)

L'IA désigne l'ensemble des théories et des techniques mises en œuvre en vue de réaliser des machines capables de simuler l'intelligence humaine.

Vision par Ordinateur (VO)

La VO, également connue sous le nom de Computer Vision, est une discipline de l'intelligence artificielle visant à examiner de manière approfondie et à décoder les informations contenues dans une image ou une séquence vidéo.

LISTE DES FIGURES

Figure 1 : Organigramme de TIR.....	4
Figure 2 : Quadrants du sein	11
Figure 3 : Structure du sein	11
Figure 4 : Présence de masse dans le sein.....	14
Figure 5 : Présence de calcification dans le sein.....	14
Figure 6 : Correspondances entre un neurone formel et biologique	19
Figure 7 : Représentation mathématique du neurone formel	20
Figure 8 : Architecture des RNCs	27
Figure 9 : Exemple de rembourrage.....	28
Figure 10 : Application de la foulée.....	29
Figure 11 : Processus global du traitement de notre modèle	35
Figure 12 : Nombre de données par classe.....	37
Figure 13 : Distribution des pixels	38
Figure 14 : Extraction du ROI.....	39
Figure 15 : Normalisation et redimensionnement des images	40
Figure 16 : Augmentation des images.....	42
Figure 17 : Couche d'auto attention.....	45
Figure 18 : Matrice de confusion	47
Figure 19 : Courbe AUC-ROC	50
Figure 20 : Grad-CAM architecture.....	51
Figure 21 : Diagramme de cas d'utilisation "Examen de mammographie"	56
Figure 22 : Diagramme de séquence "Authentification" [3].....	58
Figure 23 : Diagramme de séquence "Examen de mammographie"	59
Figure 24 : Diagramme de classes	60
Figure 25 : Page de connexion	66
Figure 26 : Page d'accueil	66
Figure 27 : Page de diagnostic par la VO	67
Figure 29 : Page de diagnostic du radiologue 1	68
Figure 30 : Visualisation d'un résultat du modèle de VO	68
Figure 31 : Page de diagnostic du radiologue 2	69

Figure 34 : Formes des masses mammaires.....	xiv
Figure 35 : Contours des masses.....	xiv
Figure 36 : Représentation de la catégorisation de la densité mammaire	xiv
Figure 37 : Mammographe analogique Lilyum	xv
Figure 38 : Opération de convolution	xvii
Figure 39 : Mise en commun moyen.....	xvii
Figure 40 : Couche de convolution	xviii
Figure 41 : Couche de mise en commun.....	xviii
Figure 42 : Couche entièrement connectée	xix
Figure 43 : Apprentissage par transfert.....	xix
Figure 44 : Structure de MBConv et Fused-MBConv	xx
Figure 45 : Entraînement du modèle.....	xx
Figure 46 : Méthode 2TUP	xxi
Figure 47 : Organigramme des diagrammes UML	xxi

LISTE DES TABLEAUX

Tableau 1 : Planning d'exécution.....	10
Tableau 2 : Caractéristiques de la tumeur bénigne et maligne.....	12
Tableau 3 : Catégorisation de la densité mammaire	16
Tableau 4 : State d'évolution du cancer du sein	17
Tableau 5 : Grade du cancer.....	18
Tableau 6 : Ensemble de données	36
Tableau 7 : Évaluation des modèles préentraînés	43
Tableau 8 : EfficientNetV2-S architecture.....	45
Tableau 9 : Rapport de classification	49
Tableau 10 : Étude comparative des méthodes de modelisation.....	53
Tableau 11 : Acteurs du système	55
Tableau 12 : Description du cas d'utilisation "Authentification"	56
Tableau 13 : Description du cas d'utilisation "Examen de mammographie"	57
Tableau 16 : Éditeur de code.....	63
Tableau 17 : Langage de développement.....	64
Tableau 18 : Librairie.....	65
Tableau 14 : Résultats du modèle de VO.....	70
Tableau 15 : Estimation financière du projet	71
Tableau 19 : Quelques fonctions d'activations.....	xvi

INTRODUCTION

En 2020, l'observatoire mondial sur le cancer (Global Observatory of Cancer, Globocan) a recensé 19 292 789 nouveaux cas de cancer et 9 958 133 personnes décédées du cancer sur l'ensemble du globe terrestre. Il se présente comme l'une des préoccupations sanitaires majeures pour les institutions sanitaires et les gouvernements des pays du monde. Chez la femme, il attaque les seins, le col de l'utérus, les poumons, le cerveau et d'autres organes. La prévalence de détections est constatée au niveau des seins selon Globocan.

Le cancer du sein occupe une proportion de 11,7% sur l'ensemble des nouveaux cas de cancer détectés, soit 2 261 419 nouvelles détections. Le taux de mortalité enregistré en cette même année est de 6,9%, soit 684 996 décès. En Côte d'Ivoire, le cancer du sein est responsable d'un nombre important de décès, avec 1 785 cas estimés sur un total de 11 760 décès liés au cancer. L'identification et la stratification des lésions mammaires au stade précoce du développement de la tumeur constituent le point de départ essentiel pour augmenter la probabilité de succès thérapeutique. En effet, près de 75 % des cas de cancer sont attribuables à un dépistage tardif [1]. De plus, l'identification des lésions cancéreuses du sein est affectée par un nombre élevé de résultats positifs classés négatifs.

Ainsi, il est nécessaire de proposer une solution efficace dont l'objectif principal est de fournir aux radiologues un outil de dépistage du cancer du sein par l'implémentation de nouvelles technologies [2]. Dans cette optique, notre structure d'accueil nous demande de proposer une solution autour du sujet intitulé : **“Conception d'un système d'aide intégré pour la détection du cancer du sein dans un ERP utilisant des réseaux de neurones : cas du dossier patient informatisé (DPI)”**. Les enjeux autour de cette solution sont l'amélioration significative des soins de santé, l'optimisation des ressources médicales et la contribution à la recherche médicale, tout en mettant l'accent sur l'amélioration de la qualité de vie des patients et la lutte contre le cancer du sein.

La réalisation d'une telle solution pose plusieurs questions : Comment le cancer du sein est-il dépisté ? Quel serait l'impact du dépistage du cancer du sein sur les centres de santé et la santé des patients ? comment concevoir et intégrer un outil d'aide aux dépistages du cancer du sein dans un DPI existant, de manière à optimiser le processus de prise en charge des patients ? Pour répondre à cette préoccupation, nous partons sur une étude du cancer suivie de l'implémentation de réseaux de neurones de convolutions qui sont adaptés aux traitements des images. Le modèle de vision par ordinateur résultant de cette implémentation est intégré au DPI par le biais d'APIs.

La mise en œuvre de notre solution s'articule autour de trois grandes parties dont la première est la généralité, dans cette rubrique, nous tenterons de montrer un aperçu de la structure d'accueil et du projet traité. Puis dans la deuxième partie, nous ferons l'étude technique qui consiste à faire la conception et la réalisation de notre projet. Pour terminer, nous exposerons dans la troisième partie les résultats obtenus, puis les discuterons.

PRÉMIÈRE PARTIE : GÉNÉRALITÉS

Nos généralités consistent à faire une présentation de la structure d'accueil, de l'existant et du cahier des charges. Et faire le bilan des études ayant un rapport avec notre sujet.

CHAPITRE I : CADRE ET CONTEXTE DE TRAVAIL

I. Présentation de la structure d'accueil

1. Historique

Fondée en 2020, Technology Innovation Revolutionner (TIR) est une entreprise spécialisée dans la conception et la mise en œuvre de services informatiques, prodiguant des conseils et des expertises dans les systèmes d'information. Son siège social est situé dans la Zone Franche de Carrefour Mossou, VITIB SA, Immeuble VITRE, Appartement 231.

2. Structure d'accueil

La structure de TIR se compose de trois départements, placés sous la tutelle de la Direction Générale, dirigée par le Président Directeur Général, Monsieur KONE ZANA NOËL. Une vue détaillée de l'organisation de cette entreprise est présentée à travers l'organigramme ci-après :

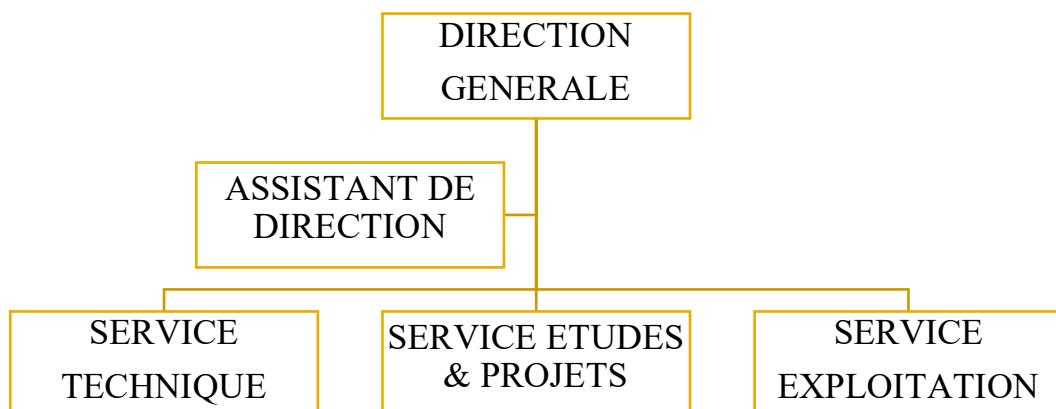


Figure 1 : Organigramme de TIR

Une description succincte du schéma est faite au travers des points suivants :

- La direction générale est chargée de la vision stratégique et de la prise de décisions globales pour l'organisation.
- L'assistant de direction fournit un appui administratif et organisationnel à la direction générale.
- Le service d'exploitation est responsable du fonctionnement quotidien des activités de la société.
- Le service études et projets s'occupent de l'analyse des besoins des clients, de la conception et de la planification des projets.
- Le service technique est chargé de superviser et de conduire les projets depuis la formulation de la problématique de recherche jusqu'à la phase d'expérimentation, dans le but d'assurer le respect des contraintes de budget, de délais et de qualité fixées initialement. Il constitue le département au sein duquel nous sommes accueillis durant la période de notre stage.

3. Secteurs d'activités et services proposés

3.1. Secteurs d'activités

Les solutions implémentées par TIR sont orientées :

- Santé par la conception et l'intégration de logiciels médicaux dédiés à des centres hospitaliers, résolvant ainsi le souci de la gestion de ces centres et de la prise en charge des patients.
- Éducation en mettant en place de systèmes facilitant la bonne gestion des établissements scolaires.
- Métiers en implémentation de solutions permettant l'optimisation des services métiers.

3.2. Services proposés

TIR a pour dessein de proposer à sa clientèle une gamme variée de prestations, comprenant l'intégration de solutions informatiques, le conseil et l'expertise en systèmes d'informations, la business intelligence, l'automatisation industrielle, ainsi que l'évaluation de risques.

II. Étude de l'existant

1. Module de radiologie

Le Dossier Patient Informatisé (DPI) est un ERP médical. Il représente le carnet de santé du patient. Accessible qu'au personnel médical et aux administrateurs, il permet de recenser les différentes informations médicales du patient ainsi que les soins et prises en charge subis par ce dernier. Il recueille les constantes, les prescriptions, les consultations, les demandes d'hospitalisation, etc. C'est un ensemble de fonctions permettant de gérer l'admission du patient dans les différents services du centre sanitaire. Il assure une continuité entre la partie clinique et la partie administrative, pour une gestion efficace tout au long du séjour du patient. Il est utilisé au sein de l'hôpital général d'Anyama et en phase de déploiement dans d'autres centres de santé. Il se compose de 27 modules dont 20 fonctionnels. Le module de radiologie compte parmi ces modules fonctionnels [3]. La prescription d'un examen de radiologie est formulée par un médecin ou un spécialiste en cas de difficultés ou de soupçons liés à l'interprétation visuelle ou physique d'une pathologie affectant le corps du patient. Le module d'imagerie au sein du DPI permet la demande d'examen et la récupération des résultats des examens d'imagerie par l'intermédiaire d'appareils tiers. Lors de la réalisation d'une radiologie, une demande est effectuée depuis le DPI. À la suite de cela, le radiologue utilise un appareil tiers pour effectuer l'opération. Dans le cas de la mammographie, ce logiciel se dénomme le mammographe comme le montre la figure 37, annexe B. Ce mammographe peut être de type le Lilyum. Lilyum est une référence dans la représentation analogue de sein.

C'est une unité complètement indépendante de mammographie permettant à des cliniciens d'obtenir les images de haute qualité. Puis, il est adéquat pour toutes les études approfondies du sein. De plus, il effectue des criblages avec la plus grande exactitude. Une fois les analyses du radiologue réalisées par le biais de l'appareil dédié, les résultats obtenus sont sauvegardés au sein du DPI.

2. Critique de l'existant

Au sein du DPI, le module de radiologie ne dispose pas d'un système intégré d'aide au diagnostic des imageries médicales. Les équipements utilisés par les radiologues leur permettent uniquement de visualiser les radiographies sous des angles améliorés. En ce qui concerne la réalisation d'une mammographie, le mammographe fournit exclusivement des images des tissus mammaires. Ces images sont extraites sous plusieurs vues. Le craniocaudal bilatéral (anglais bilateral craniocaudal CC) et oblique médio-latéral (mediolateral oblique MLO) sont les plus courantes, dont l'analyse est confiée aux radiologues. Cette interprétation prend en moyenne 30 minutes par patient. Ce temps de dépistage peut varier en fonction de la complexité de l'image. Dans certains cas, elle nécessite la validation de plusieurs radiologues pouvant ainsi s'étendre sur plusieurs semaines [4]. De plus, la complexité des images peut conduire à des erreurs de diagnostics.

III. Cahier des charges

1. Contexte du projet

En Côte d'Ivoire, la prévalence et la mortalité du cancer sont des problèmes de santé publique importants. Selon les estimations de Globocan 2020, il y a eu 17 300 nouveaux cas en Côte d'Ivoire, dont 9896 femmes et 7404 hommes. Le cancer du sein est le plus fréquent de toutes les parties du corps et sexes confondues (19,1%), suivi du cancer de la prostate (15,9%), du cancer du col de l'utérus (11,9%), du cancer du foie (6,6%), et des lymphomes non hodgkiniens

(4,9%). Les tumeurs les plus fréquemment diagnostiquées chez les femmes sont celles du sein et du col de l'utérus, avec des taux d'incidence standardisés de 44,7 et 31,2 respectivement pour 100 000 femmes. En outre, le taux de mortalité lié à la tumeur reste très élevé. En effet, les estimations pour 2020 situent le nombre de décès à environ 11 760. Ce nombre est en grande partie dû au diagnostic tardif dans approximativement 75 % des cas, le mauvais diagnostic et de la méconnaissance de la maladie cancéreuse [1]. C'est dans ce contexte de résoudre ces problématiques de plus en plus inquiétantes que l'entreprise TIR, nous demande de proposer une solution d'aide à la détection du cancer du sein à partir des images de mammographies à l'aide de l'intelligence artificielle au sein de son logiciel de dossier patient informatisé.

2. Objectifs

L'objectif général de ce stage, c'est de mettre en place une application web au sein du DPI permettant le dépistage du cancer du sein à partir de la mammographie à l'aide des algorithmes d'intelligence artificielle. Pour y parvenir, nous déterminons cinq objectifs spécifiques du projet, à savoir :

- Collecter et préparer un ensemble de mammographies.
- Déterminer les facteurs indiquant la présence d'un cancer du sein dans une mammographie.
- Implémenter un modèle de détection du cancer du sein sur les images de mammographies.
- Intégrer le système au sein du DPI.
- Tester la fiabilité du système.

3. Besoins

Notre système a pour besoins fonctionnels de :

- Traiter les images de mammographies numériques et extraire les caractéristiques pertinentes pour la détection d'anomalies.
- Déetecter les anomalies potentielles dans les images de mammographies ;
- Fournir une classification du diagnostic (normal et cancéreuse) ;
- Afficher les résultats des analyses des images mammographiques en temps réel pour permettre aux radiologues de les utiliser pendant leur diagnostic.

Puis comme besoins non fonctionnels, le système se doit d'être :

- Précis et fiable, avec une sensibilité et une spécificité supérieure à 70% pour la détection des anomalies mammaires.
- Convivial et facile à utiliser pour les radiologues de la clinique.
- En mesure de traiter un nombre élevé d'images mammographiques en un temps raisonnable (25 images en moins de 5 minutes).
- Sécurisé et protégé contre tout accès non autorisé.

4. Contraintes

En termes de contraintes, le résultat doit être conforme aux exigences d'interopérabilité et de technologies utilisées par le DPI, ainsi qu'aux normes de protection des données de santé en vigueur dans la région.

5. Planning d'exécution

La livraison du système doit se faire dans le mois juin 2023 avec un 1^{er} prototype fonctionnel. En plus d'un rapport esquissant le projet sur toutes ses coutures.

Tableau 1 : Planning d'exécution

Durée	Période	Tâche	Livrable
3 semaines	6 février – 27 février 2023	Étude du projet	Rapport descriptif de l'existant et de l'état de l'art
5 semaines	28 février – 04 avril 2023	Formation autour des concepts et outils clés au projet	Rapport descriptif des compétences acquises
8 semaines	05 avril – 31 mai 2023	Conception et réalisation de la solution	Plateforme web de dépistage du cancer du sein Modèle de vision par ordinateur Intégration du modèle à la plateforme
2 semaines	31 mai – 13 juin 2023	Mise en œuvre et application	Plateforme déployée en environnement test

CHAPITRE II : ÉTUDE DU PROJET

I. Cancer du sein

1. Anatomie du sein

Les hommes comme les femmes ont des seins, mais ces organes ne sont fonctionnels que chez les femmes. Ils ont un rôle biologique qui est la production de lait pour nourrir les bébés. Situés à l'avant du thorax, ils s'étendent de la clavicule jusqu'au milieu du sternum et de l'aisselle. Les seins sont asymétriques et ne contiennent pas de muscles, mais sont soutenus par des ligaments. Leur composition comprend une glande mammaire, du tissu conjonctif et du tissu adipeux qui leur donne leur forme et leur volume. La glande mammaire est constituée de lobes contenant des lobules sécrétaires qui produisent le lait transporté par des canaux galactophores jusqu'au mamelon. Les seins sont divisés en quadrants, avec le quadrant supéro-externe et la région centrale étant les plus fréquemment touchés par le cancer du sein en raison de la concentration de tissu glandulaire [5].

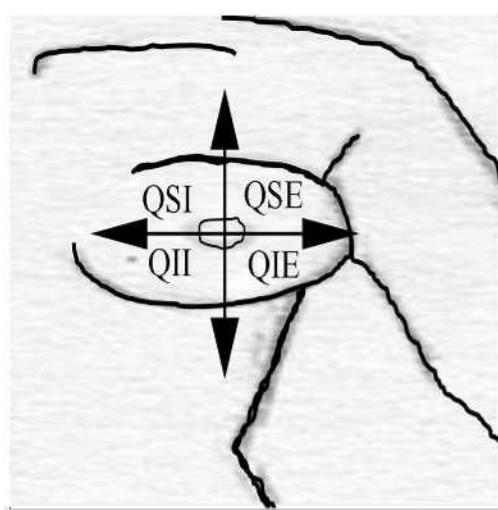


Figure 2 : Quadrants du sein

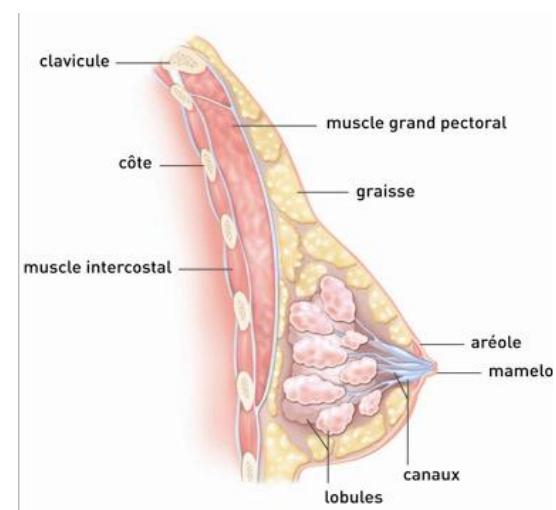


Figure 3 : Structure du sein

2. Définition du cancer du sein

Le cancer du sein est une maladie qui se caractérise par une prolifération incontrôlable et anormale des cellules mammaires. Cette prolifération peut entraîner la formation de tumeurs qui peuvent être bénignes ou malignes, et peuvent perturber le fonctionnement normal des organes environnants [6]. Les traits caractéristiques de ces tumeurs mammaires sont détaillés dans le tableau 2.

Tableau 2 : Caractéristiques de la tumeur bénigne et maligne

Tumeur bénigne	Tumeur maligne
Bien délimitée	Mal délimitée
Encapsulée	Non encapsulée
Histologiquement semblable au tissu d'origine	Plus ou moins semblable au tissu d'origine
Cellules régulières	Cellules irrégulières (cellules cancéreuses)
Évolution lente	Évolution rapide
Refoulement sans destruction des tissus voisins	Envahissement des tissus voisins
Aucune récidive locale après une opération chirurgicale	Récidive possible après une opération chirurgicale
Pas de prolifération	Prolifération

Les adénocarcinomes sont les types les plus courants de cancer du sein, représentant environ 95 % des cas diagnostiqués. Ils se développent le plus souvent à partir des cellules épithéliales des canaux que des cellules épithéliales des lobules de la glande mammaire. Ils sont répartis en deux grandes familles qui sont les adénocarcinomes *in situ* et les adénocarcinomes infiltrants [7].

2.1 Adénocarcinomes in situ

Le terme "adénocarcinome in situ" ou "cancer in situ" fait référence à une condition dans laquelle les cellules cancéreuses se trouvent uniquement à l'intérieur des canaux ou des lobules de la glande mammaire, sans avoir envahi les tissus environnants. C'est un stade précoce du cancer du sein, où les cellules cancéreuses sont confinées et n'ont pas franchi la membrane basale. Ce type de cancer est considéré comme bénin et peut être traité avec succès. Le cancer in situ peut se présenter sous deux formes : le cancer canalaire in situ (CCIS), plus fréquent, et le cancer lobulaire in situ (CLIS), plus rare.

2.2 Adénocarcinomes infiltrant

Le carcinome infiltrant est une forme de cancer du sein dans laquelle les cellules cancéreuses ont envahi les tissus environnants, notamment les canaux et les lobules. Il est principalement de type canalaire, représentant environ 80% des cas. Les cancers infiltrants ont la capacité de se propager aux ganglions lymphatiques et à d'autres parties du corps. Les cellules cancéreuses peuvent atteindre les ganglions axillaires sous les bras ainsi que des organes tels que les os, le foie, les poumons ou le cerveau.

3. Mécanisme de prolifération

La division cellulaire normale dans notre organisme peut parfois entraîner des erreurs génétiques qui sont généralement corrigées par les mécanismes de protection de l'organisme. Cependant, lorsque ces mécanismes échouent ou que les erreurs s'accumulent, les cellules peuvent devenir cancéreuses et échapper à la mort cellulaire programmée. Puis se propager à leur descendance ce qui entraîne une prolifération incontrôlée. Ce processus de prolifération cancéreuse s'applique aux cancers du sein [7].

4. Pathologies mammaires liée au cancer du sein

Le cancer du sein se manifeste de différentes manières, et il est souvent classé en pathologies bénignes et malignes. Les signes les plus courants sont de masses et de calcifications comme illustrées ci-dessous respectivement à la figure 4 et figure 5.

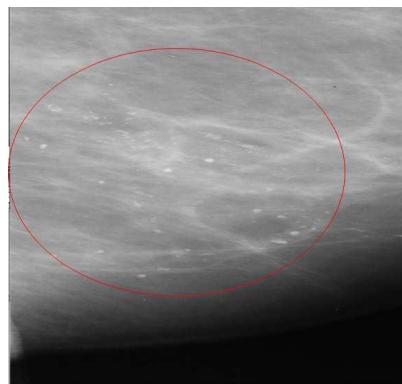


Figure 4 : Présence de masses dans le sein Figure 5 : Présence de calcifications dans le sein

4.1. Calcification

Les calcifications mammaires sont de deux types : les macrocalcifications et les microcalcifications. Elles se traduisent par des dépôts de calcium dans le tissu du sein, sont assez répandues et généralement non associées au cancer du sein. Toutefois, afin d'écartier tout doute quant à la présence de cette maladie, le radiologue évalue leur taille, leur forme et leur distribution grâce aux images mammographiques [7].

4.1.1. Macrocalcification

Les macrocalcifications, dont les caractéristiques sont la formation de dépôts de calcium épais dans le sein, surviennent préférentiellement chez les femmes de plus de 50 ans. Leur apparition est souvent associée à des altérations bénignes du tissu mammaire. Dans ce contexte, il convient de souligner que la découverte de macrocalcifications ne conduit pas automatiquement à une recommandation de biopsie.

4.1.2. Microcalcification

Les microcalcifications sont de minuscules amas de calcium détectables dans le sein. Lorsqu' elles apparaissent isolées ou groupées en amas lors de la mammographie, elles peuvent évoquer une suspicion de cancer du sein, tel qu'un CCIS. Dans cette éventualité, le radiologue préconise la réalisation d'une biopsie afin de confirmer ou d'infirmer la présence d'un cancer.

4.2. Masse

Une masse dans le sein est une lésion suspecte pouvant être associée ou non à des calcifications. Elle fait l'objet d'une caractérisation en fonction de trois critères : sa forme, son contour et sa densité. Cette caractérisation suit la classification du système de description et d'analyse des données en imagerie mammaire, communément appelé sous le nom de BIRADS (Breast Imaging Reporting and Data System) [7].

4.2.1. Forme

Les formes permettent de discriminer les diverses morphologies que prend une masse mammaire. Elles sont soit circulaires, ovales, lobulées ou encore irrégulières, comme illustré sur la figure 34, annexe A.

4.2.2. Contours

Les configurations du contour peuvent altérer la morphologie de la masse. Elles sont de types : circonscrites (nettes), microlobulés, masquées et indistinctes (mal définies). Elles sont illustrées au travers de la figure 35, annexe A. Les masses présentant des contours irréguliers, épineux ou indistincts évoquent une probabilité accrue de malignité.

4.2.3. Densité

La densité mammaire se réfère à la proportion relative des différents types de tissus dans le sein féminin. Lorsque le tissu mammaire est dense (blanc ou gris), la détection de lésions cancéreuses peut s'avérer plus ardu dû à son camouflage. La classification BIRADS établit une évaluation de la densité du tissu mammaire en quatre catégories distinctes, tel que clarifié dans le tableau 3 et la figure 36, annexe A.

Tableau 3 : Catégorisation de la densité mammaire

Catégorie	Descriptions
Catégorie 1	Le sein présente une prédominance de tissu adipeux, avec moins de 25% de la glande mammaire.
Catégorie 2	Le sein se compose d'un mélange de tissu adipeux et de tissu glandulaire avec des opacités fibroglandulaires dispersées, couvrant approximativement de 25 à 50% de la glande mammaire.
Catégorie 3	Le tissu mammaire présente une densité élevée et hétérogène, occupant approximativement de 51 à 75% de la glande mammaire, ce qui peut rendre la détection de petites masses plus difficile.
Catégorie 4	Le tissu mammaire est caractérisé par une densité extrêmement élevée et homogène, recouvrant plus de 75% de la glande mammaire, ce qui peut affecter la sensibilité de la mammographie.

5. Classification du cancer du sein

Le stade et le grade du cancer du sein représentent des éléments de renseignement majeurs pour caractériser cette maladie [7].

5.1. Stade du cancer

Le stade du cancer du sein est déterminé en fonction de l'ampleur de la tumeur et de son degré de dissémination dans les tissus avoisinants ainsi qu'aux organes distants. Plus le chiffre est élevé, plus le cancer du sein s'est propagé dans les tissus et organes de l'organisme. Ci-dessous le tableau 4 présente les différents paliers de cette évolution.

Tableau 4 : State d'évolution du cancer du sein

Stade	Définition	Évolution
Stade 0	CCIS	Modification précancéreuse non invasive
Stade 1	Le cancer n'est présent que dans le sein et les ganglions lymphatiques de l'aisselle ne sont pas touchés ou ne le sont que de façon microscopique.	Cancer du sein précoce
Stade 2	Le cancer est plus important qu'au stade 1 et/ou se trouve dans quelques ganglions lymphatiques voisins.	Cancer du sein précoce
Stade 3	Le cancer est plus étendu qu'au stade 2, ou touche la peau du sein ou la paroi thoracique ou quelques ganglions lymphatiques proches du sein.	Cancer du sein localement avancé
Stade 4	Le cancer s'est propagé à d'autres parties du corps.	Cancer du sein avancé

5.2. Grade du cancer

Le grade du cancer correspond à la morphologie des cellules cancéreuses en comparaison avec les cellules saines. Il permet de déterminer la rapidité de progression de la tumeur. La catégorisation des différents niveaux de grades est exposée dans le tableau 5 ci-dessous.

Tableau 5 : Grade du cancer

Grade	Définition
Grade 1 (grade faible)	Généralement, à croissance lente, les cellules et structures cancéreuses ressemblent davantage à des cellules mammaires normales.
Grade 2 (grade intermédiaire)	Taux de croissance intermédiaire, le cancer présente moins de caractéristiques du tissu mammaire normal.
Grade 3 (grade élevé)	Croissance rapide, les cellules cancéreuses sont très différentes des cellules mammaires normales.

II. Réseaux de neurones

1. Présentation des réseaux de neurones

Un réseau de neurones désigne un ensemble de neurones formels interconnectés qui permettent de construire un modèle d'apprentissage profond à partir d'exemples de données. Cette méthode est souvent décrite comme une modélisation mathématique du cerveau humain, dans laquelle chaque neurone artificiel est conçu pour traiter des informations et les transmettre aux neurones connectés. Le fonctionnement de ces réseaux est principalement basé sur les calculs de dérivées différentielles [8].

1.1. Définition d'un neurone formel

Un neurone artificiel, également appelé neurone formel, est une représentation synthétique d'un neurone biologique, qui est une cellule caractérisée par plusieurs éléments tels que :

- des synapses pour se connecter à d'autres neurones ;
- des dendrites pour recevoir des entrées ;
- des axones pour envoyer des signaux à d'autres neurones ou fibres musculaires ;
- un noyau qui réagit aux stimuli d'entrée pour activer les sorties.

Par conséquent, un neurone formel (figure 6) est une abstraction artificielle d'un neurone biologique, dans laquelle :

- les entrées sont représentées par les dendrites ;
- les poids sont utilisés pour modéliser les synapses ;
- la fonction de transfert, appelée également fonction d'activation, représente le corps cellulaire ;
- la sortie est similaire à l'axone du neurone biologique.

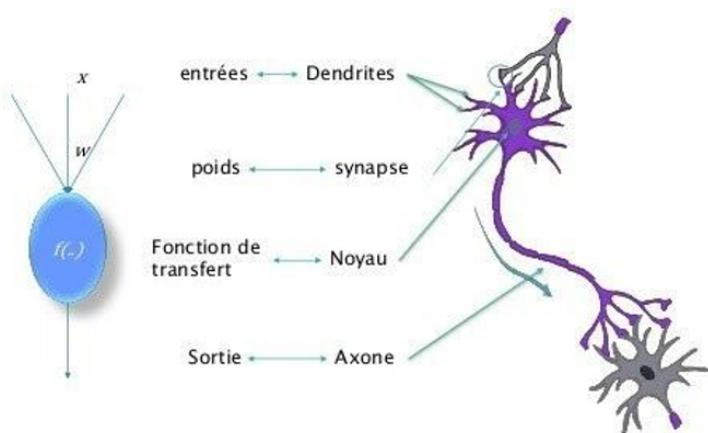


Figure 6 : Correspondances entre un neurone formel et biologique

1.2. Formulation mathématique du neurone formel

Pour fournir un résultat, un neurone effectue une succession d'opérations mathématiques au sein de sa structure (figure 7).

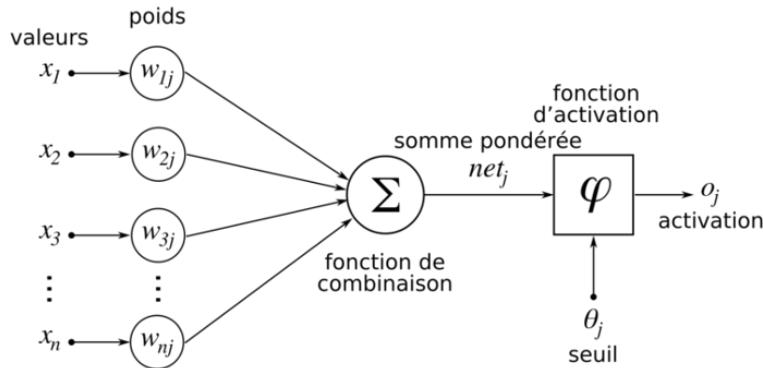


Figure 7 : Représentation mathématique du neurone formel

1.2.1. Fonction de combinaison

L'opération de combinaison s'effectue entre les valeurs d'entrées et les poids. Elle est décrite au travers des points suivants :

- chaque poids est représenté par une valeur notée w_{ij} , indiquant le poids allant du neurone formel i au neurone formel j ;
- chaque poids transmet une information ou un stimulus provenant du neurone source i, noté x_i ;
- la valeur de ce stimulus est modulée par le poids qui relie les neurones i et j ;

$$x_i * w_{ij} \text{ (I)}$$

- le neurone j reçoit donc la somme de tous les stimuli multipliés par leurs poids respectifs ;

$$\sum x_i * w_{ij} \text{ (II)}$$

- si l'on note n le nombre de stimuli en entrée du neurone j , la notation mathématique complète est la somme de toutes les multiplications des valeurs des n entrées par les poids associant ces entrées au neurone j considéré.

$$\sum_{i=0}^n x_i * w_{ij} \text{ (III)}$$

Le neurone formel j utilise ensuite une fonction de transfert pour traiter cette somme.

1.2.2. Fonction d'activation

La fonction d'activation joue un rôle crucial dans le fonctionnement du neurone artificiel. Elle s'inspire du fonctionnement d'un neurone biologique. Elle permet au neurone d'émettre une sortie lorsque l'ensemble des stimuli en entrée atteint le seuil d'excitabilité. Trois types de fonctions d'activation existent, telles que :

- La fonction binaire en escalier, elle dépend d'une valeur seuil qui décide si un neurone doit être activé ou non.
- La fonction d'activation linéaire, elle est également appelée "pas d'activation" ou "fonction d'identité" (multipliée par 1,0). Elle est une fonction dans laquelle l'activation est proportionnelle à l'entrée. La fonction ne fait rien à la somme pondérée de l'entrée, elle recrache simplement la valeur qui lui est donnée.
- La fonction d'activation non linéaire, elle résout les limites de la fonction d'activation linéaire rencontrées lors de la propagation avant ou de la rétropropagation (explosion du gradient¹, disparition du gradient²). Voir tableau 19, annexe B.

1- **L'explosion du gradient** désigne l'accumulation de gradients, entraînant de très grandes mises à jour des poids du modèle de réseau neuronal pendant la formation.
 2- **La disparition du gradient** désigne la perte de gradients lors de l'entraînement du modèle.

2. Types de réseaux de neurones

Il existe plusieurs types de réseaux de neurones, chacun avec ses propres caractéristiques et applications. Voici quelques exemples :

- Les réseaux de neurones à propagation directe (ou feedforward), les données circulent dans un seul sens, sans boucle de rétroaction. Ils sont utilisés pour des tâches de classification ou de régression.
- Les réseaux de neurones récurrents, les données peuvent circuler dans des boucles de rétroaction, permettant ainsi d'analyser des séquences de données, comme des séquences temporelles ou des données textuelles.
- Les réseaux de neurones convolutifs, ils sont principalement utilisés pour l'analyse d'images ou de vidéos. Ils utilisent des couches de convolution pour extraire des caractéristiques des images et peuvent ainsi reconnaître des objets, des visages, etc.
- Les réseaux de neurones de type auto-encodeur, ils sont utilisés pour l'apprentissage non supervisé et permettent de compresser les données d'entrée dans une représentation plus compacte, tout en préservant leur structure et leur information.
- Les réseaux de neurones de type GAN (Generative Adversarial Networks), ils sont utilisés pour la génération de données synthétiques, comme des images ou des vidéos, en apprenant à générer des données qui ressemblent le plus possible à des données réelles.
- Les réseaux de neurones de type attention, ils sont utilisés pour l'analyse de séquences de données, en permettant de donner plus d'importance à certaines parties de la séquence en fonction du contexte.

III. État de l'art

Au cours des dernières années, l'avènement de l'utilisation des réseaux de neurones dans la détection du cancer du sein a connu un essor considérable. En effet, la détection manuelle de cette maladie étant limitée, il est apparu nécessaire de mettre en place des algorithmes permettant à la machine de réaliser cette tâche de manière plus efficace. Ainsi, diverses approches ont été développées pour la détection automatique du cancer du sein à l'aide de l'intelligence artificielle. Dans ce présent ouvrage, nous procédon à l'examen des approches ayant produit de bons résultats. Puis sur ces acquis, développer la nôtre qui sera employée pour le traitement de notre cas d'étude. Les données étant des images, toutes les études ont pour architecture de base (backbone en anglais) les réseaux de neurones convolutifs. À cette architecture est ajoutée diverses méthodes telles que la segmentation, l'augmentation des données, la biologie et l'utilisation des modèles préentraînés.

1. Approches de résolution

1.1. Détection d'objets

La détection d'objets est une tâche complexe de traitement d'images dont l'objectif est d'analyser des images ou des vidéos afin de localiser et d'identifier des objets d'intérêt. Dans le cadre spécifique de la détection du cancer du sein, cette technique permet de détecter la présence et la localisation de tumeurs dans une image, tout en les classant en différentes catégories. Bien que cette méthode puisse fournir des résultats satisfaisants, il convient de noter qu'elle nécessite un ensemble de données préalablement étiqueté pour être efficace. Pour approfondir cette approche, l'article de recherche des experts tels que ceux de l'équipe dirigée par R. Agarwal, O. Diaz, X. Lladó, M. H. Yap et R. Martí peut apporter des informations complémentaires [9].

1.2. Augmentation des données

À travers l'article de K. H. Cha, N. Petrick, A. Pezeshk, C. G. Graff, D. Sharma, A. Badal et B. Sahiner au sujet “Evaluation of data augmentation via synthetic images for improved breast mass detection on mammograms using deep learning, Journal of Medical Imaging”. Nous pouvons percevoir l’augmentation des données comme le fait de générer des images de synthèse à partir d’images d’origine. Ces nouvelles images sont ajoutées à notre jeu de données initiales. Cela permet de disposer d’une grande quantité de données pour notre modèle, ce qui améliore la précision de ce dernier. Toutefois, il faut noter que la création d’images de synthèse peut biaiser les résultats de notre modèle [10].

1.3. Segmentation

Les travaux basés sur la segmentation ont pour vocation de localiser de manière précise la tumeur une fois sa présence détectée. La segmentation permet de mesurer les caractéristiques de la tumeur, telles que sa forme, son volume et sa texture. Cela peut aider les professionnels de la santé à évaluer l’agressivité de la tumeur et à prendre des décisions éclairées sur les options de traitement. Les résultats de cette approche peuvent être observés au sein des travaux des chercheurs Anuj Kumar Singh et Bhupendra Gupta [11].

1.4. Biologie

Lors de notre revue littéraire, nous avons pris connaissance d’une approche ingénieuse autour du sujet “Classification d’images biologiques simples et complexes à l’aide des moments de Krawtchouk et des moments pseudo-Zernike généralisés : étude de cas avec des images d’ailes de mouches et de mammographies de cancer du sein”. Elle permet de partir de la structuration des ailes de mouches pour extraire des variables importantes au sein des images mammaires.

La découverte de ses nouvelles caractéristiques permet à ces chercheurs d'accroître les performances de leur modèle [12].

1.5. Modèles préentraînés

Ces modèles sont les plus couramment utilisés dans la littérature pour les tâches de détection du cancer du sein à partir d'images de mammographies, que ce soit au sein des quatre pistes de recherches énoncées ci-dessous ou indépendamment. Elles permettent d'utiliser des architectures existantes, initialisées avec leurs meilleurs poids. Elles ont fait leurs preuves pour diverses tâches spécifiques. Ce principe de réutilisation de modèle est connu sous le nom de l'apprentissage par transfert (transfert learning en anglais) [13].

2. Présentation de notre approche

Pour la conception de notre modèle de vision par ordinateur, en nous appuyant sur les travaux présentés précédemment. Nous optons pour des architectures implémentant des modèles préentraînés basés sur des réseaux de neurones de convolutions pour la détection du cancer. Puis, nous complétons en sortie de ceux-ci, des couches d'auto attentions, une couche de sortie suivie d'une carte d'activation de classe pondérée par le gradient. Elle permet de mettre en évidence les régions qui ont été pertinentes lors de la décision de notre modèle. Par elle, le radiologue peut avoir une segmentation visuelle de la zone de l'image abritant la tumeur. De plus, des techniques d'augmentation sont implémentées dans notre approche lors de l'entraînement de notre modèle, permettant ainsi de lutter contre le sur-apprentissage. Pour terminer, ces résultats sont implantés dans une plateforme ludique destinée aux radiologues.

DEUXIÈME PARTIE : ÉTUDE TECHNIQUE

L'étude technique consiste à décrire le processus de conception de notre modèle de VO et l'étude conceptuelle de notre application. Elle comporte toutes les indications nécessaires à la compréhension de notre travail.

CHAPITRE III : CONCEPTION DU MODULE DE VISION PAR ORDINATEUR

I. Réseaux de neurones convolutifs

1. Généralités

Les réseaux neuronaux convolutifs (RNCs) représentent une architecture de réseau profond qui, de manière autonome, apprend à partir des données. Leur utilité est particulièrement significative pour la détection de motifs dans les images, permettant ainsi la reconnaissance d'objets.

2. Architecture des RNCs

Pour pouvoir effectuer une détection de motifs par le biais de l'architecture des RNCs, les images subissent plusieurs transformations.

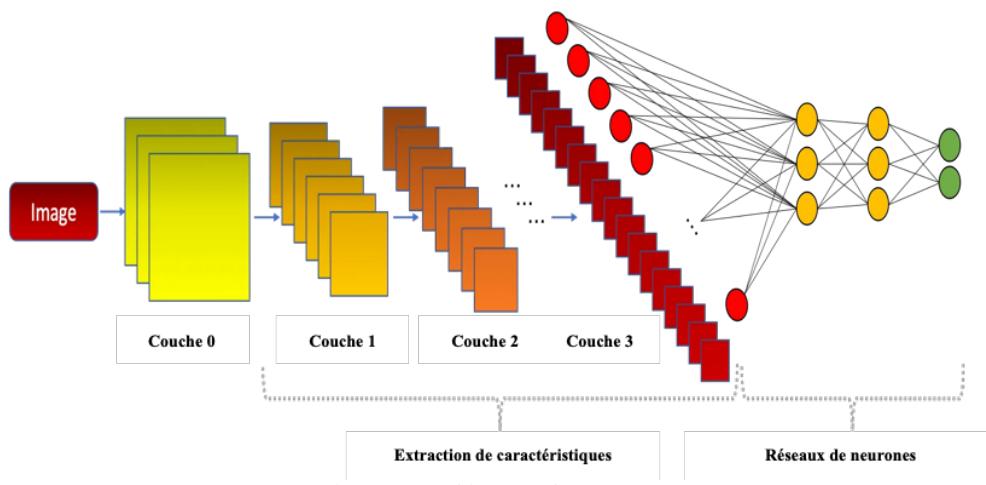


Figure 8 : Architecture des RNCs

2.1. Filtres

Les filtres sont de bords verticaux ou horizontaux. Ils représentent le premier traitement appliqué aux images. Par elles l'on peut obtenir diverses informations, notamment les contours des objets dans l'image. Sur le plan mathématique, l'expression du filtre à bord vertical (FBV) et horizontal (FBH) peut-être :

$$FBV = \begin{bmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{bmatrix} = FBH(IV)$$

2.2. Opérations

2.2.1. Rembourrage

Le rembourrage représenté par p correspond à l'ajout d'une bordure que nous pouvons superposer sur le contour d'une image, afin d'en modifier la taille ou la forme. À titre d'exemple, l'illustration 9 montre l'ajout d'une bordure supplémentaire à une image de 6x6 image, qui a permis de la convertir en une image de 8x8 image.

Entrée						Sortie			
3	0	1	2	7	4	0	0	0	0
1	5	8	9	3	1	0	3	0	1
2	7	1	5	1	3	0	1	5	8
1	7	5	4	9	0	0	2	7	1
1	3	2	7	5	8	0	1	7	5
6	0	2	1	5	7	0	1	3	2

Figure 9 : Exemple de rembourrage

2.2.2. Foulée

La notion de foulée désigne la distance parcourue entre chaque application de la fonction de convolution lors du traitement d'une image. Cette distance est exprimée en nombre de pixels et peut-être ajustée à l'aide du paramètre s . En effet, une valeur élevée de s permet de réduire la taille de la sortie, tandis qu'une valeur faible permet de conserver une sortie plus grande. Ainsi, la figure suivante illustre un produit de convolution effectué avec une foulée de 1, où la somme des éléments est calculée de manière itérative pour chaque bloc de pixels de l'image.

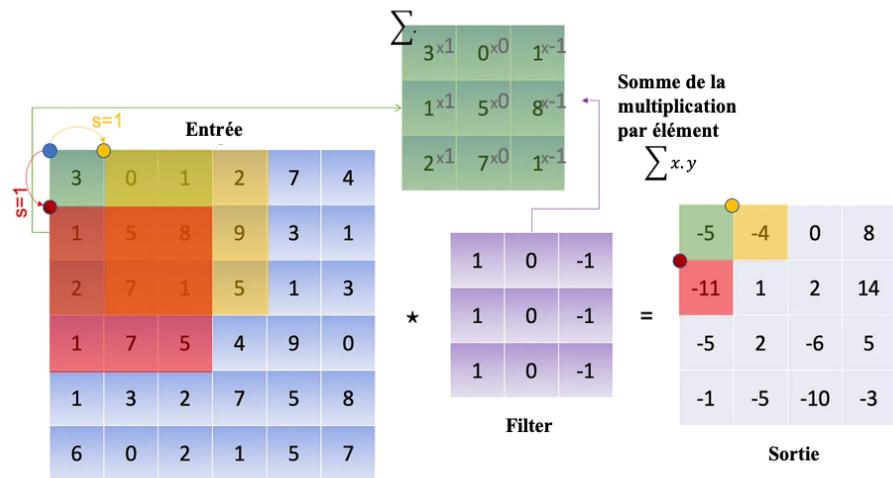


Figure 10 : Application de la foulée

Où :

- x : abscisse
- y : ordonnée
- s : foulée

2.2.3. Convolution

La convolution désigne le procédé mathématique qui consiste à fusionner deux fonctions afin d'obtenir une troisième fonction. Dans le cadre d'un réseau neuronal convolutif (RNC), cette opération est appliquée aux données d'entrée en utilisant un filtre ou un noyau, générant ainsi une carte de caractéristiques. Elle correspond à la somme du produit par élément dans chaque bloc en fonction de la dimension des blocs. La figure 38, annexe B illustre un exemple de produit convolution.

L'expression mathématique est :

$$Conv(I, K)_{x,y} = \sum_{i=1}^{n_n} \sum_{j=1}^{n_w} \sum_{k=1}^{n_c} K_{i,j,k} I_{x+i-1, y+j-1, k} (V)$$

$$Dim(Conv(I, K)) = (\left\lfloor \frac{n_H + 2p - f}{s} + 1 \right\rfloor, \left\lfloor \frac{n_W + 2p - f}{s} + 1 \right\rfloor); s > 0 \ (VI)$$

$$Dim(Conv(I, K)) = (n_H + 2p - f, n_W + 2p - f); s = 0 \ (VII) [14]$$

Avec :

- i : index, $i \in [1, 2, \dots, n]$
- n_H : taille de la hauteur
- n_W : taille de la largeur
- n_C : nombre de canaux
- f : taille du filtre
- K : filtre
- I : entrée
- $Conv$: convolution
- Dim : dimension

2.2.4. Mise en commun

Lors de cette étape, les caractéristiques de l'image sont sous-échantillonnées en vue de résumer les informations. Cette opération est réalisée pour chaque canal, ce qui a pour effet de ne modifier que les dimensions (n_H, n_W) tout en préservant n_C . En pratique, cela implique le déplacement d'un filtre sans paramètres à apprendre à travers l'image, en suivant une certaine foulée, et l'application d'une fonction aux éléments sélectionnés. Il existe plusieurs types de rembourrage, les plus utilisés sont :

- La mise en commun moyen, on fait la moyenne sur les éléments présents sur le filtre (figure 39, annexe B).
- La mise en commun maximum, on renvoie le maximum des éléments du filtre.

La dimension obtenue après la mise en commun sachant que Pool correspondant à la mise en commun est :

$$Dim \left(Pool \left(Conv(I, K) \right) \right) = \left(\left\lfloor \frac{n_H + 2p - f}{s} + 1 \right\rfloor, \left\lfloor \frac{n_W + 2p - f}{s} + 1 \right\rfloor \right); s > 0 \text{ (VIII)} \quad [14]$$

2.3. Couches

Toutes ces opérations énoncées plus haut s'appliquent à une série de couches au sein d'une architecture complète du RNC.

2.3.1. Couche de convolution

La couche de convolution avec une fonction d'activation est formulée mathématiquement comme suit :

$$\forall n \in [1, 2, \dots, n_C^{[l]}],$$

$$Conv(a^{[l-1]}, K^{(n)})_{x,y} = \psi^{[l]} \sum_{i=1}^{n_H^{[l-1]}} \sum_{j=1}^{n_W^{[l-1]}} \sum_{k=1}^{n_C^{[l-1]}} K_{i,j,k}^{(n)} a_{x+i-1, y+j-1, k}^{[l-1]} + b_n^{[l]} \quad (IX)$$

$$Dim(Conv(a^{[l-1]}, K^{(n)})) = (n_H^{[l]}, n_W^{[l]}) \quad (X)$$

$$Dim(a^{[l]}) = (n_H^{[l]}, n_W^{[l]}, n_C^{[l]}) \quad (XI)$$

$$\begin{aligned} \text{avec } n_{H/W}^{[l]} &= \frac{n_{H/W} + 2p^{[l]} - f^{[l]}}{s^{[l]}} \text{ si } s > 0, n_{H/W}^{[l]} = n_{H/W} + 2p^{[l]} - f^{[l]} \text{ si } s = 0 \text{ et } n_c \\ &= \text{nombre de filtres} \quad [14] \end{aligned}$$

Où :

- l : position de la couche
- $a^{[l]}$: entrée à la couche l , $a^{[0]}$ correspond à l'image entrée
- $b_n^{[l]}$: biais de la $n - i$ ème convolution à la couche l
- $\psi^{[l]}$: Fonction d'activation à la couche l

Une illustration est exposée à la figure 40, annexe B.

2.3.2. Couche de mise en commun

Une fois le calcul au niveau de la couche de convolution effectué, l'on passe à celle de la couche de mise en commun, $\phi^{[l]}$: Fonction de mise en commun représente la fonction mise en commun. Le calcul de cette couche a pour expression :

$$a_{x,y,z}^{[l]} = Pool(a^{[l-1]})_{x,y,z} = \phi^{[l]} \left(\left(a_{x+i-1, y+j-1, z}^{[l-1]} \right)_{(i,j) \in [1, 2, \dots, f^{[l]}]^2} \right) \quad (XII) \quad [14]$$

Une visualisation graphique est exposée à la figure 41, annexe B.

2.3.3. Couche entièrement connectée

La couche entièrement connectée consiste en une combinaison de la fonction Affine ($z_j^{[i]}$) et de la fonction d'activation ($a_l^{[i]}$). A la suite de cette couche, nous avons la couche de sortie. La formule ci-contre et la figure 42, annexe B illustrent la somme de la couche entièrement connectée en fonction de l'index.

$$z_j^{[i]} = \sum_{l=1}^{n_{i-1}} w_{j,l}^{[i]} a_l^{[i-1]} + b_j^{[i]} \quad (XIII)$$
$$a_l^{[i]} = \psi^{[i]}(z_j^{[i]}) \quad (XIV) \quad [14]$$

2.3.4. Couche de sortie

La couche de sortie est dotée d'une fonction d'activation, soit sigmoïde ou softmax pour les tâches de classification, soit linéaire pour les tâches de régression.

2.4. Types de propagations

La propagation en avant et la rétropropagation implémentent les opérations présentées précédemment.

2.4.1. Propagation en avant

La propagation vers l'avant (ou feedforward) désigne le calcul et la sauvegarde des variables intermédiaires (y compris les sorties) d'un réseau de neurones, de la couche d'entrée à la couche de sortie. Ces variables sont calculées par le biais des opérations étudiées préalablement.

2.4.1. Propagation en arrière

La rétropropagation (ou backpropagation) est la méthode utilisée pour calculer les gradients des paramètres d'un réseau neuronal. Essentiellement, cette méthode parcourt le réseau en sens inverse, de la couche de sortie à la couche d'entrée, en utilisant la règle de dérivation en chaîne. L'algorithme stocke toutes les variables intermédiaires (dérivées partielles) nécessaires pour calculer les gradients par rapport aux paramètres spécifiques. Cela permet de réduire la fonction de coût du modèle en mettant à jour les paramètres (les poids et le biais) du modèle. Supposons que nous disposions des fonctions $z = f(x)$ et $a = g(z)$, où les tenseurs d'entrée et de sortie x , z et a peuvent avoir des formes arbitraires. En appliquant la règle de la chaîne, nous sommes en mesure de calculer la dérivée de a par rapport à x de la manière suivante :

$$\frac{\delta a}{\delta x} = \frac{\delta a}{\delta z} \frac{\delta z}{\delta x} \quad (XV) \quad [14]$$

2.5. Algorithme succinct de l'entraînement d'un RNC

Les prédictions lors de la phase d'entraînement au sein des réseaux de convolution sont implémentées au sein d'un algorithme qui suit les étapes suivantes :

- Initialisation des paramètres du modèle
- Faire une boucle sur le nombre d'époques
 - Application de la propagation avant
 - Calcul des valeurs prédites sur les données d'entraînement
 - Evaluation de la fonction coût
 - Application de la rétropropagation
 - Optimisation des paramètres du modèle pour la réduction de la fonction coût [14]

II. Modèle de Vision par ordinateur

Pour classifier nos images mammaires, notre modèle de vision par ordinateur (VO) effectue plusieurs opérations. L'architecture ci-après combine toutes ces opérations pour présenter un processus global du traitement [15].

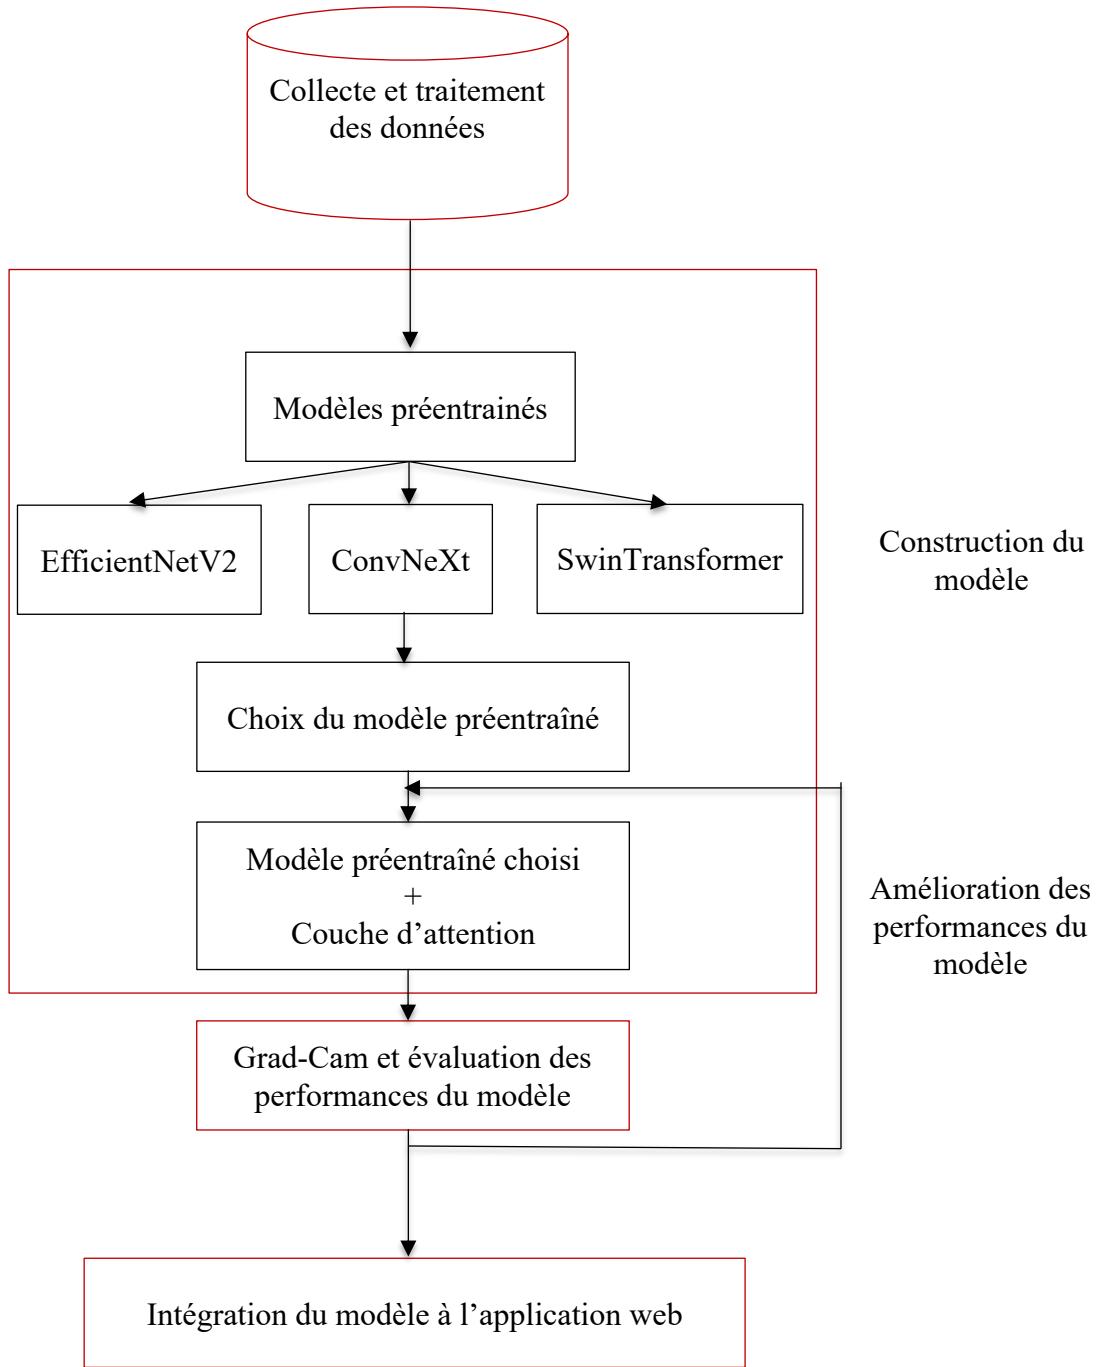


Figure 11 : Processus global du traitement de notre modèle

1. Collecte et traitement de données

1.1. Collecte de données

Afin d'élaborer notre modèle de VO, la première étape primordiale réside dans l'acquisition des données. La fiabilité et la validité de notre modèle s'appuient indubitablement sur ces données. Dans le cadre de ce projet, nous avons sélectionné avec rigueur trois ensembles de données provenant de la plateforme Kaggle. Le premier ensemble de données de mammographie nous est fourni par la Radiological Society of North America (RSNA), une institution réputée. Ensuite, nous nous appuyons sur la Chinese Mammography Database (CMMMD), une base de données chinoise dédiée à la mammographie. Enfin, nous exploitons le Curated Breast Imaging Subset (CBIS) of DDSM (Digital Database for Screening Mammography), qui constitue notre dernière source de données. Consultez le tableau ci-dessous pour avoir une vue détaillée de ces ensembles.

Tableau 6 : Ensemble de données

Jeux de données	Description
RSNA	L'ensemble de données mammaires du RSNA regroupe les résultats de 54706 mammographies réalisées sur 11913 patients.
CMMMD	Au sein du CMMMD, on y retrouve 5202 images mammographiques produites sur la base de 1775 patients.
CBIS-DDSM	CBIS-DDSM fournit 5391 résultats de mammographie collectés à partir de 2620 patients.

1.2. Traitement de données

Les données acquises sur cette plateforme ne sont pas intrinsèquement interprétables par notre modèle de VO. Par conséquent, nous entreprenons des traitements spécifiques dans le but de les rendre accessibles à une compréhension et utilisation appropriée par notre modèle.

1.2.1. Exploration de données

L'exploration des données consiste à identifier les incongruités présentes dans nos données, c'est une démarche qui facilite le prétraitement de nos données en déterminant :

- le format ;
- la distribution ;
- l'échelle ;
- la corrélation.

Elle permet également de mettre en évidence des détails essentiels liés aux données. Lors de la fouille de nos données, nous sortons les conclusions suivantes :

- DICOM est le format ;
- l'équilibre de l'ensemble de données est fortement altéré entre les examens présentant une présence de cancers et ceux sans. Nous avons 5 226 cas positifs et 54 580 cas négatifs, comme le montre la figure 12 ;

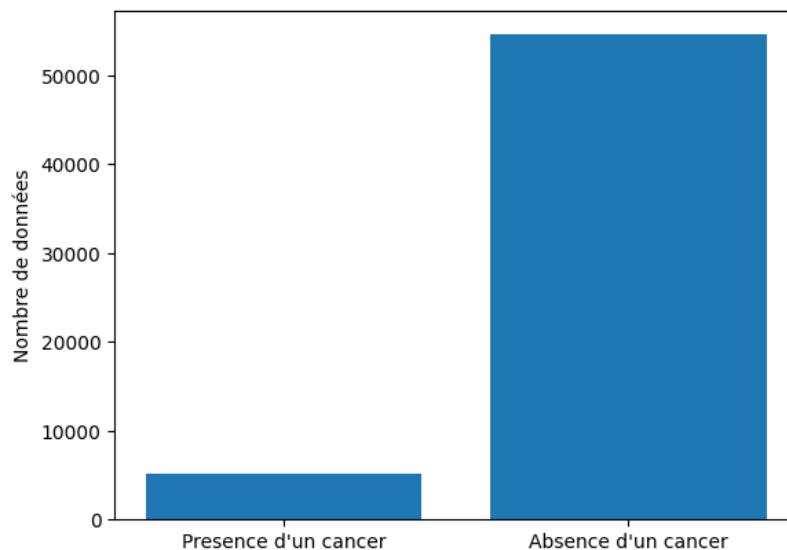


Figure 12 : Nombre de données par classe

- les images recueillies sont de différentes dimensions et présentent des zones de non-intérêt ;
- la distribution des pixels présente une variation considérable. Cette distribution nous est présentée par la figure 13.

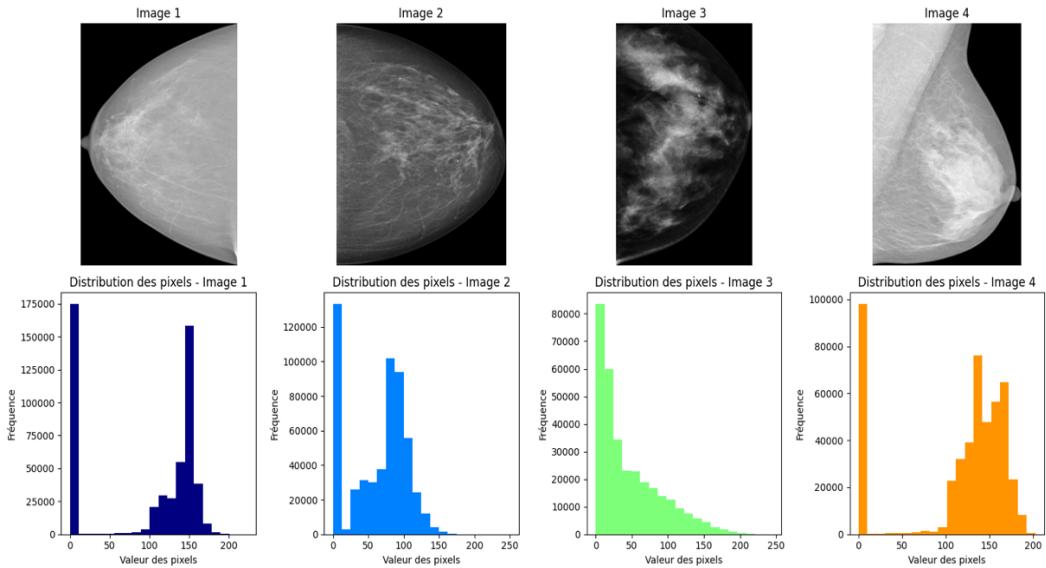


Figure 13 : Distribution des pixels

1.2.2. Prétraitements des données

Suite aux observations faites sur nos jeux de données, nous allons procéder à une série d'opérations de prétraitements.

1.2.2.1. Conversion des images

Le format DICOM représente un protocole normalisé largement adopté pour la transmission d'images médicales, et est utilisé dans de nombreux établissements de santé. Il établit les normes de stockage et de transmission des images médicales. Nos algorithmes de VO ne sont pas capables d'interpréter ce format directement. Nous procédons donc à la conversion des images au format PNG (Portable Network Graphics). Le choix du format PNG est préféré par rapport à d'autres formats tels que le JPEG (Joint Photographic Experts Group) en raison de sa compression sans

perte, de sa prise en charge de la transparence et de sa taille de fichier plus importante.

1.2.2.2. Extraction de la zone d'intérêt

L'extraction de la zone d'intérêt (Region of interest : ROI en anglais) est le premier traitement à appliquer sur nos images PNGs obtenues suite à la conversion. Nos images variantes entre le blanc et noir. Nous avons décidé d'implémenter un algorithme permettant de récupérer les zones d'intérêt sur la base des pixels non vides en fonction d'un seuil. Cet algorithme itère chaque pixel de l'image. La figure 14 laisse transparaître ses deux opérations.

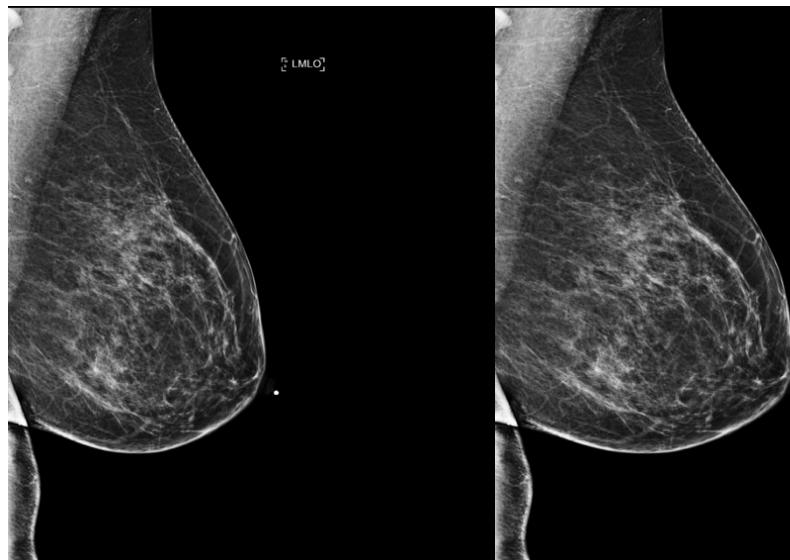


Figure 14 : Extraction du ROI

1.2.2.3. Normalisation et redimensionnement des images

Suite à l'opération d'extraction du ROI, nous uniformisons la taille des zones d'intérêt extraites avant de procéder à leur normalisation. L'opération de normalisation dans notre cas utilise l'écart type et la moyenne. Elle permet :

- de centrer les valeurs de pixel autour d'une moyenne, ce qui favorise la convergence du réseau lors de l'apprentissage de notre modèle ;

- de garantir une plage de valeurs de pixel cohérent entre différentes images, ce qui permet à notre modèle d'apprendre de manière plus efficace ;
- de réduire l'impact des variations de luminosité, de contraste et d'intensité globale entre les images, ce qui rend nos algorithmes plus résistants aux différentes conditions d'éclairage et améliore nos capacités de généralisation.

Les résultats de cette opération sont observables à la figure 15 et ces formules mathématiques sont :

$$\text{Ecart type } (\sigma) = \sqrt{\frac{\sum_{i=1}^n (x_i - \mu)^2}{N}} \quad (XVI)$$

$$\text{Moyenne } (\mu) = \frac{\sum_{i=1}^n x_i}{N} \quad (XVII)$$

Avec :

- x_i : valeur du i – ème élément
- N : nombre de valeurs

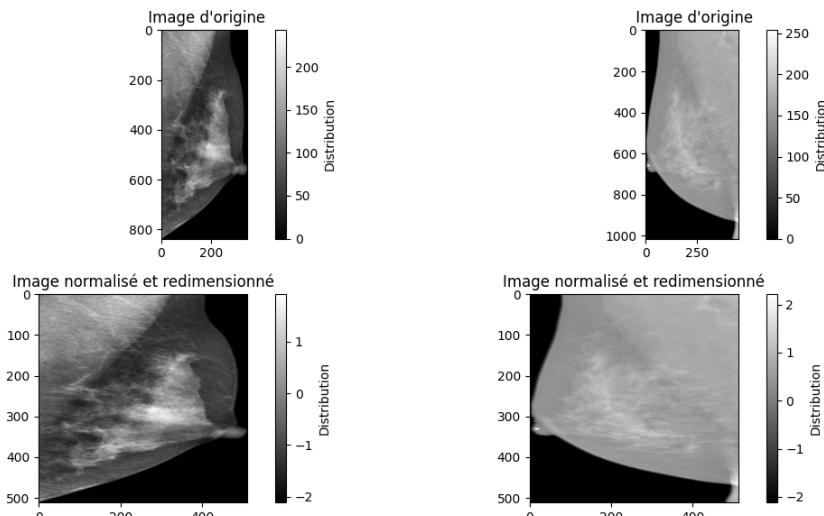


Figure 15 : Normalisation et redimensionnement des images

1.2.2.4. Scinder notre ensemble de données

Une fois le prétraitement de nos données effectué, nous procédons à la sélection de 25 000 résultats de mammographies en fonction de nos ressources de calcul que nous offre l'abonnement colab pro +. Ces résultats contiennent 19 774 cas négatifs et 5 226 cas positifs au cancer. Puis, nous allons diviser notre jeu de données en

sous-ensembles distincts pour les entraînements, validations et tests. Notre sous-ensemble d'entraînement, de validation et de test est respectivement 71,252%, 23,748% et 5%.

1.2.2.5. Augmentation des images

Le jeu de données final obtenu, nous passons à l'augmentation de notre sous-ensemble d'entraînement à travers de multiples techniques d'augmentation. Puis ajustons les paramètres de ces différentes techniques. Ce processus d'augmentation est continu avec des ajustements, l'on l'arrête lorsque nous obtenons les augmentations réduisant le coût de notre modèle. Il offre des bienfaits tels que :

- réduire le surapprentissage ;
- améliorer la généralisation des données ;
- améliorer les performances du modèle.

Les techniques d'augmentation que nous appliquons sont :

- le retournement horizontal, il retourne l'entrée horizontalement autour de l'axe y ;
- le retournement vertical, il retourne l'entrée verticalement autour de l'axe x ;
- la courbe de tonalité aléatoire, elle modifie aléatoirement la relation entre les zones claires et sombres de l'image en manipulant sa courbe de tonalité ;
- le recadrage de taille aléatoire, il extrait une partie aléatoire de l'entrée et la redimensionne à une certaine taille ;
- le contraste de luminosité aléatoire, il altère aléatoirement la luminosité et le contraste de l'image d'entrée ;
- la rotation, la mise à l'échelle et le décalage, ils appliquent aléatoirement des transformations affines : translater, redimensionner et pivoter l'entrée ;
- la transformation élastique, il divise l'image en une grille de petits carrés ou pixels et en déplaçant de manière aléatoire ces pixels dans une plage définie. Ce déplacement crée des déformations locales, étirant ou comprimant l'image dans différentes régions ;

- l'abandon grossier, il masque de manière aléatoire des régions de l'image, introduisant efficacement une perte localisée.

Le rendu de la combinaison de ces transformations est observable à la figure 16.

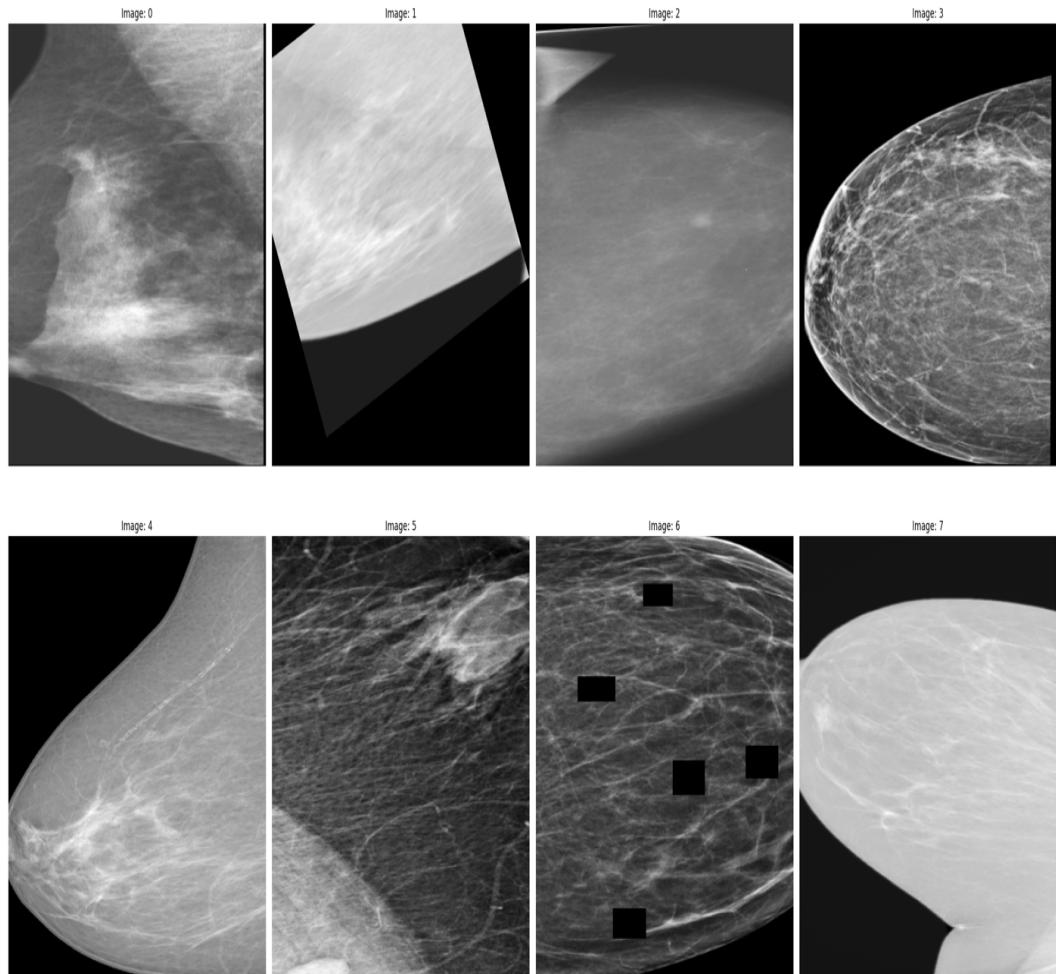


Figure 16 : Augmentation des images

2. Construction du modèle de détection du cancer du sein

La figure 11 présente l'architecture succincte de notre modèle de détection de tumeurs au sein des images mammaires. Cette architecture se compose de modèles préentraînés, de couches d'attention et d'une fonction sigmoïde en sortie. Elle nous

permet d'effectuer une classification. Cette classification est binaire, car nous avons deux classes à prédire. Elles sont représentées par les mammographies cancéreuses et non cancéreuses.

2.1. Modèles préentraînés

Pour la réalisation de cette tâche de classification binaire, une multitude de modèles préentraînés s'offre à nous. Parmi ces modèles, nous sélectionnons convnext³, efficientnetv2 et swintransformer⁴ qui se présente comme les trois plus performants. Leur performance est évaluée en fonction de leur score sur des jeux de données tels que COCO⁵, CIFAR-10⁶, ImageNet21k⁷ et ImageNet22k⁷ [16] [17] [18]. Puis, l'on les a évalués sur notre ensemble de données. EfficientNetV2 a produit de meilleurs résultats (tableau 7) lors de cette mise à l'épreuve en s'adaptant à nos données.

Tableau 7 : Evaluation des modèles préentraînés

Dimension	Modèle	Score AUC-ROC
600*600	SwinTransformer (Small-21k)	0,65
600*600	ConvNeXt (Small-21k)	0,67
600*600	EfficientNetV2 (S-21k)	0,72

-
- 3- **ConvNeXt** est un modèle convolutif, inspiré de la conception des transformateurs de vision.
 - 4- **SwinTransformer** désigne transformateur de vision hiérarchique utilisant des fenêtres décalées.
 - 5- **COCO** désigne un ensemble de données de détection, de segmentation et de sous-titrage d'objets à grande échelle (330 000 images dont 200 000 étiquetées).
 - 6- **CIFAR-10** désigne se compose de 60 000 images couleur 32x32 réparties en 10 classes, avec 6 000 images par classe.
 - 7- **ImageNet21k** et **ImageNet22k** servent d'ensemble de données principal pour la préformation de modèles d'apprentissage en profondeur pour les tâches de VO.

EfficientNetV2 est un modèle convolutif plus petit et à entraînement rapide. Il correspond à la version 2 d'EfficientNet qui repense la mise à l'échelle des modèles pour les réseaux de neurones convolutifs [19]. L'obtention de cette version a nécessité l'utilisation de Fused-MBConv en remplacement de certains MBConv, observable à la figure 39, annexe B. MBConv (Mobile Inverted Residual Bottleneck Convolution en français Convolution de goulot d'étranglement résiduel inversé mobile) est conçu pour trouver un équilibre entre l'efficacité et la performance du modèle en tirant parti des convolutions séparables en profondeur (depthwise conv 3×3) et des goulets d'étranglement linéaires. Tandis que MBConv fusionné (Fused-MBConv) vise à réduire les frais généraux associés aux convolutions séparées en profondeur et ponctuelles dans le MBConv standard (voir figure 44). EfficientNetV2 dispose en son sein de 7 architectures variant en fonction de leur complexité qui impacte le nombre de paramètres à optimiser. Ces architectures sont :

- EfficientNetV2-S : 22 millions de paramètres.
- EfficientNetV2-M : 54 millions de paramètres.
- EfficientNetV2-L : 120 millions de paramètres.
- EfficientNetV2-S (21k) : 22 millions de paramètres.
- EfficientNetV2-M (21k) : 54 millions de paramètres.
- EfficientNetV2-L (21k) : 120 millions de paramètres.
- EfficientNetV2-XL (21k) : 208 millions de paramètres.

Le tableau 8 montre l'architecture de fonctionnement de notre modèle EfficientNetV2-S (21k). Une fois l'image prétraitée insérée dans une telle architecture, elle subit plusieurs opérations. Puis la dernière couche renvoie les caractéristiques extraites de l'image. Ces variables sont ensuite passées à notre couche d'attention sous forme de matrice [18].

Tableau 8 : EfficientNetV2-S architecture

Etape	Opération	Foulée	#Canaux	#Couche
0	Conv3x3	2	24	1
1	Fused-MBConv1	1	24	2
2	Fused-MBConv4	2	48	4
3	Fused-MBConv4	2	64	4
4	MBConv4, k3x3, SE0.25	2	128	6
5	MBConv6, k3x3, SE0.25	1	160	9
6	MBConv6, k3x3, SE0.25	2	256	15
7	Conv1x1 & Pooling & FC	-	1280	1

2.2. Couche d'auto attention

Nous avons expérimenté des couches d'auto attention à la sortie d'EfficientNetV2-S (21k). Ces couches utilisées généralement dans les transformeur⁸ pour l'interprétation des données textuelles offrent au modèle les possibilités de :

- capturer des dépendances à longue distance ;
- modéliser le contexte de manière plus efficace.

L'auto attention pondère les différentes parties de l'entrée sur la base de leurs relations mutuelles. L'architecture de cette opération est présentée au travers de la figure 17.

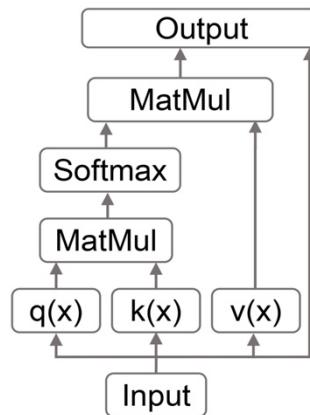


Figure 17 : Couche d'auto attention

8- Transformer est une architecture de réseaux de neurones qui vise à résoudre des tâches séquence à séquence tout en gérant facilement les dépendances à longue portée.

Les opérations de Softmax et MatMul désignent respectivement la fonction softmax et la multiplication de matrices. Ces cartes de caractéristiques d'entrée (input) sont transformées en q, k et v, qui jouent les rôles de requête, clé et valeur, respectivement [20]. La formulation mathématique est :

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{\text{Dim}(k)}}\right)V \quad (\text{XVIII}) \quad [20]$$

Avec $\text{Dim}(k)$ correspondant à la dimension de k. A la suite des couches (output), nous avons ajouté la fonction d'activation sigmoïde pour effectuer nos prédictions.

3. Évaluation et optimisation du modèle

3.1. Évaluation

3.1.1. Matrice de confusion

Après avoir adapté notre modèle de détection de cancer en fonction des images collectées, il est impératif de procéder à une évaluation minutieuse de ses performances dans sa tâche. À cet effet, nous avons utilisé une mesure appelée la matrice de confusion. Une matrice de confusion, également connue sous le nom de tableau de contingence, offre un résumé des résultats de prédiction dans un problème de classification. Les prédictions correctes et incorrectes sont révélées et classées par catégories, permettant ainsi une comparaison avec les valeurs réelles. Cette matrice permet de comprendre les sources de confusions du modèle lorsqu'il effectue des prédictions, en identifiant non seulement les erreurs commises, mais surtout les types d'erreurs de prédiction. Dans notre cas, elle met en confrontation les prédictions cancéreuses positives et négatives. Tous les paramètres d'estimation de la matrice de confusion sont basés sur quatre entrées distinctes, à savoir :

- Les vrais positifs (VP) correspondent au nombre d'images mammographiques présentant une tumeur correctement prédite.

- Les vrais négatifs (VN) sont le nombre d'images mammographiques saines correctement prédictes.
- Les faux positifs (FP) désignent le nombre d'images mammographiques saines classifiées cancéreuses.
- Les faux négatifs (FN) font allusion au nombre d'images mammographiques cancéreuses classifiées saines.

Ci-dessous, la figure suivante présente la matrice de confusion de la détection des tumeurs.

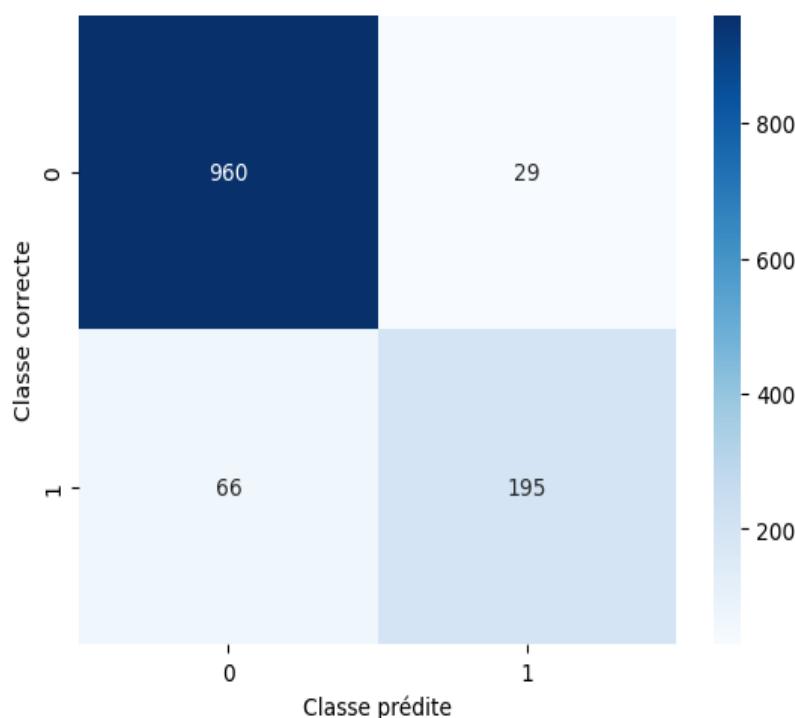


Figure 18 : Matrice de confusion

À l'examen de notre échantillon de données dédié à la détection du cancer du sein, il est observé que le nombre de faux positifs (FP) et de faux négatifs (FN) s'élèvent respectivement à 66 et 29. Par ailleurs, les vrais positifs (VP) représentent 195 tandis que les vrais négatifs (VN) représentent 960. La présence de FP et de FN révèle des erreurs d'étiquetage dans un certain nombre de cas de maladies. Par cette matrice, l'on constate que notre modèle arrive à effectuer une classification cancéreuse. Il performe plus pour la détection des images saines.

Nous allons avérer ou non nos constats avec l'évaluation des métriques du rapport de classification qui sont le rappel, la précision, la spécificité, le taux de réussite, f1-score et la courbe AUC-ROC.

3.1.1.1. Métriques du rapport de classification

Le rappel (sensibilité) est défini comme le rapport du nombre total de vrais positifs par le nombre total de vrais positifs plus le nombre total de faux négatifs au sein de l'ensemble de données.

$$Rappel = \frac{VP}{VP + FN} \quad (XIX)$$

La précision est définie comme le rapport du nombre total de vrais positifs classé correctement par le nombre total de prédictions positives.

$$Précision = \frac{VP}{VP + FP} \quad (XX)$$

La spécificité définit le nombre total de fausses prédictions dans l'ensemble de données totales.

$$Spécificité = \frac{VN}{VN + FP} \quad (XXI)$$

Le taux de réussite définit le nombre total de vraies prédictions dans l'ensemble de données totales.

$$Taux\ de\ réussite = \frac{VP + VN}{VP + VN + FP + FN} \quad (XXII)$$

Le F1-score correspond à une combinaison entre le rappel et la précision.

$$F1 - Score = 2 * \frac{Rappel * Précision}{Rappel + Précision} \quad (XXIII)$$

La courbe AUC-ROC (Area Under the Receiver Operating Characteristic curve en français Aire sous la courbe de caractéristique de fonctionnement du récepteur) est tracée avec sensibilité par rapport à la 1- spécificité. Lors de l'évaluation des performances de notre modèle, nous accordons une importance particulière à la courbe AUC-ROC étant donné qu'elle est plus adaptée à la tâche de classification binaire.

3.1.1.2. Rapport de classification

Les résultats des métriques d'évaluation des performances de notre modèle sur les données de test sont exposés dans le tableau et la figure qui suivent, permettant ainsi leur présentation claire et détaillée.

Tableau 9 : Rapport de classification

	Précision	Rappel	F1-score	Nombre
Absence de tumeur	0.94	0.97	0.95	989
Présence de tumeur	0.87	0.75	0.80	261
Taux de réussite			0.92	1250
Moyenne macro	0.90	0.86	0.88	1250
Moyenne pondérée	0.92	0.92	0.92	1250

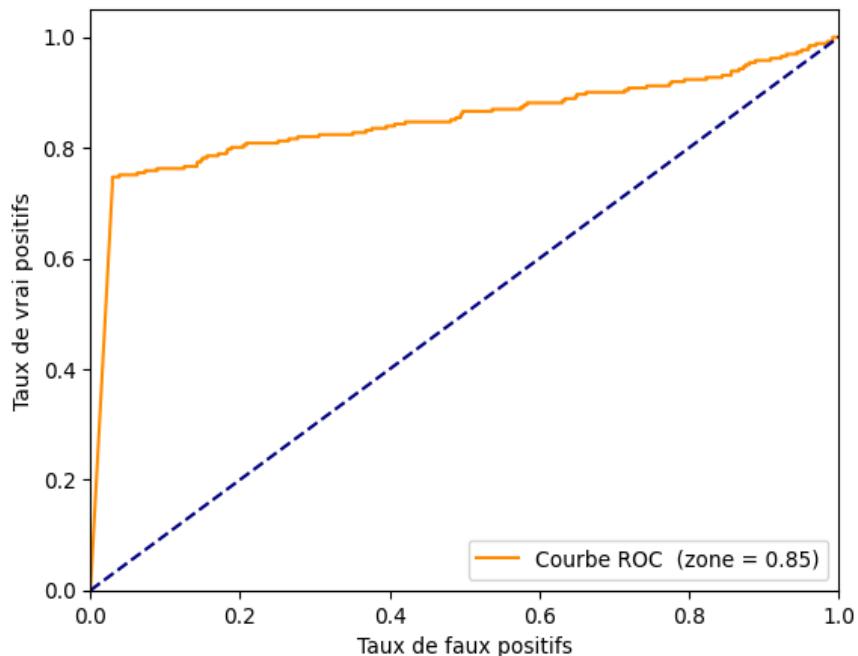


Figure 19 : Courbe AUC-ROC

Sur la base de la courbe ROC, l'on peut affirmer que notre système est capable de classifier des images mammographiques avec un score AUC-ROC (un taux de vrais positifs) de 0.85 et supérieur à 0.80 respectivement pour un seuil de taux de faux positifs à 0.5 et supérieur à 0.2. Puis le rapport de classification vient confirmer nos commentaires sur le comportement de notre modèle énoncé sur la base de la matrice de confusion.

3.1.1.3. Grad-CAM

Grad-CAM (Gradient-weighted Class Activation Mapping en français Cartographie de l'activation de la classe pondérée par le gradient) est une approche de visualisation fréquemment employée dans le but de comprendre les choix effectués par un réseau de neurones à convolution. Elle nous génère des cartes thermiques qui mettent en évidence les régions d'activation associées aux diverses classes présentes dans les images, permettant ainsi d'identifier les zones ayant influencé la décision finale du réseau. Dans notre cas, cette génération d'informations se base sur l'utilisation de notre modèle sans la couche de sortie. À partir de ces informations, l'on peut améliorer les performances de notre modèle.

Vaswani et all. [20] donne plus d'information sur cette méthode qui est décrite de manière succincte par la figure 20.

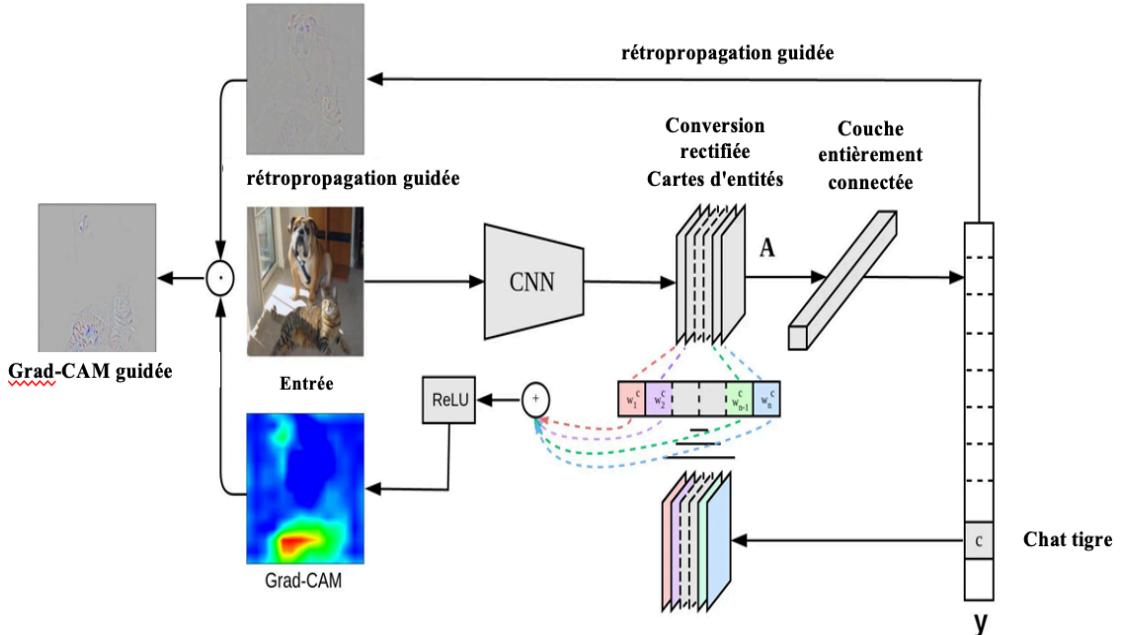


Figure 20 : Grad-CAM architecture

Grad-CAM effectue deux opérations mathématiques principales pour l'obtention de ces rendus. Ce sont :

$$\alpha_k^c = \underbrace{\frac{1}{Z} \sum_i \sum_j}_{\text{Calcul du gradient par rétropropagation}} \underbrace{\frac{\partial y^c}{\partial A_{ij}^k}}_{\text{mise en commun moyenne}} \quad (XXIV)$$

$$L_{Grad-CAM}^c = \text{ReLU} \left(\sum_k \alpha_k^c A_{ij}^k \right) \quad (XXV) \quad [21]$$

Avec :

y^c : score de la classe c

A_{ij}^k : carte de variable de la k à l'index i et j

α_k^c : linéarisation partielle de la classe c à la couche k

$L_{Grad-CAM}^c$: carte de localisation de la classe c

3.2. Optimisation des performances du modèle

L'optimisation des paramètres de notre modèle de VO est une étape très importante. En effet, cette étape consiste à la recherche de paramètres qui permettent d'obtenir des performances accrues. Les paramètres les plus importants offrant de meilleures détections des cas de tumeurs au sein de nos images mammaires trouvés sont :

- Taille du lot de données : 12.
- Nombre d'époques pour l'entraînement : 5.
- Nombre de divisions du jeu de données pour la validation croisée : 4.
- Nombre d'époques avant arrêt anticipé lors de l'entraînement : 3.
- Taux d'apprentissage : 1e-4.
- Optimiseur : AdamW⁹.
- Ordonnanceur : CosineAnnealingLR¹⁰.

9- **AdamW** est une méthode d'optimisation stochastique qui modifie l'implémentation typique de la décroissance du poids dans Adam, en découplant la décroissance du poids de la mise à jour du gradient.

10- **CosineAnnealingLR** réduit le taux d'apprentissage par une fonction cosinus.

CHAPITRE IV : ÉTUDE CONCEPTUELLE DE L'APPLICATION WEB

I. Choix de la méthode de conception

1. Étude comparative

Tableau 10 : Étude comparative des méthodes de modélisation

MÉTHODE	DESCRIPTION	AVANTAGE	INCONVÉNIENT
Merise	C'est une méthode séquentielle reposant sur la séparation des données et traitements	Adaptation à la conception logicielle Pérennité du modèle Largement utilisée par les entreprises	Difficile à incrémenter Difficulté de maintenances
2TUP	C'est une méthode en Y dissociant la branche technique et fonctionnelle reposant sur l'utilisation d'UML	Itérative et incrémentale Réutilisation d'une branche Modélisation en UML	Requiert bonne connaissance en UML. Fausse la conception lorsqu'une branche est incorrecte
Scrum	C'est une méthode itérative et incrémentale reposant sur une collaboration collective	Responsabilité collective Simplicité de processus Augmentation de la productivité	Adaptée aux petites équipes Dysfonctionnement lors du départ brusque d'un membre d'équipe

2. Choix de la méthode de conception

Suite à l'étude comparative des méthodes MERISE, 2TUP et SCRUM exposant leurs avantages et inconvénients au sein du tableau ci-dessus. Nous avons choisi la méthode de conception 2TUP (figure 46, annexe C), associée au langage UML. En effet, le 2TUP met en œuvre un processus uniifié, incrémental (il évolue), itératif (il peut être ajusté), réutilisable et orienté utilisateurs (il tient compte des besoins exprimés par les utilisateurs : radiologues). De plus, elle facilite la réalisation des projets avec un court délai [22].

II. Identification des acteurs et besoins du système

1. Présentation du langage de UML

UML, abréviation de Unified Modeling Language, est un langage de modélisation standardisé composé d'un ensemble intégré de diagrammes, développé pour aider les développeurs de systèmes et de logiciels à spécifier, visualiser, construire et documenter les artefacts des systèmes logiciels, ainsi que pour la modélisation d'entreprise et d'autres systèmes non logiciels. La modélisation avec UML est constituée diagrammes qui sont scindés en deux grands groupes, à savoir les diagrammes structurels et les diagrammes comportementaux, voir la figure 47 de l'annexe C pour en savoir plus.

2. Identification des acteurs du système

Le tableau ci-dessous expose les trois acteurs au centre du fonctionnement de notre système aux vues du cahier des charges :

Tableau 11 : Acteurs du système

Utilisateur	Tout radiologue et administratif qui utilisent l'application.
Administrateur	Tout personnel inscrit ayant les droits d'accès au service de radiologie.
Système	Ensemble d'objets qui sont programmés en arrière-plan.

3. Identification des besoins du système

3.1. Diagramme de cas d'utilisation

Le diagramme de cas d'utilisation modélise le comportement d'un système et permet de capturer les besoins du système. Notre figure ci-dessous expose les interactions graphiques entre le radiologue, le mammographe, le modèle de VO et le système. L'appareil de mammographie et notre modèle de VO sont tous deux des acteurs secondaires.

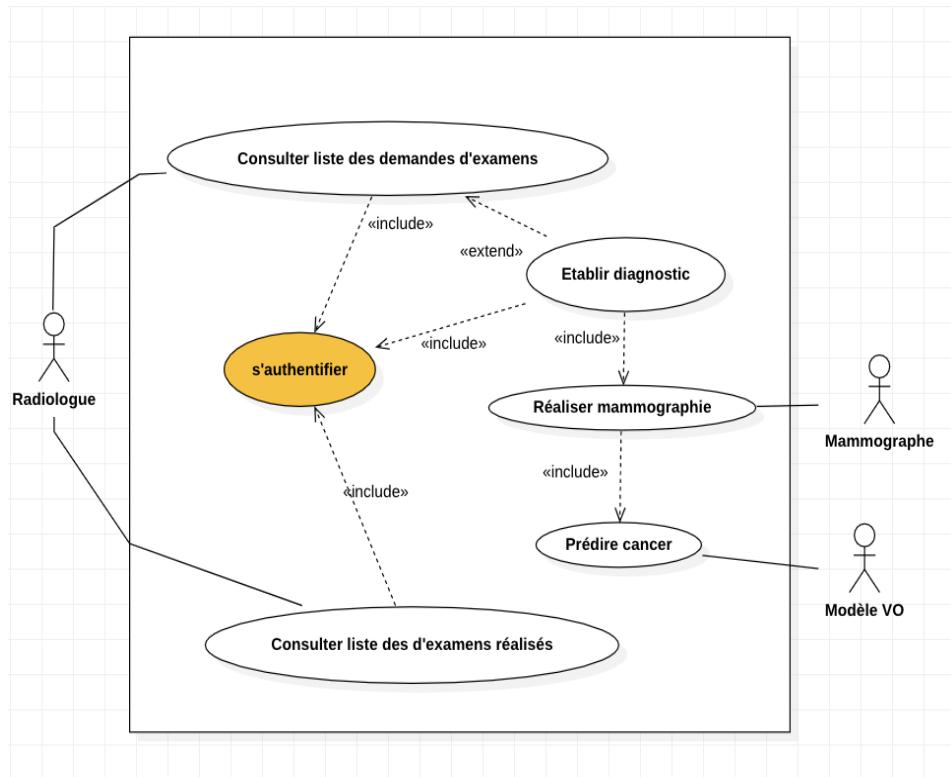


Figure 21 : Diagramme de cas d'utilisation "Examen de mammographie"

Après avoir présenté une illustration graphique de notre cas d'utilisation, nous nous adonnons à une analyse textuelle exhaustive pour révéler davantage de spécificités. Les tableaux subséquents exposeront les diverses descriptions textuelles.

Tableau 12 : Description du cas d'utilisation "Authentification"

Titre	Authentification
Résumé	L'acteur démarre une session
Acteur	Le radiologue ou l'administrateur (utilisateur)
Évènement déclencheur	Un clic
Précondition	Pour le radiologue ou l'administrateur, être inscrit.
Scénario nominal	L'utilisateur renseigne le formulaire de connexion, l'envoie et obtient un accusé de réception du système.

Scénario alternatif ou contraintes	<p>1) En cas d'identifiant incorrect : on demande à l'utilisateur d'entrer à nouveau ses identifiants.</p> <p>2) En cas de souci technique : il est demandé à l'utilisateur d'entrer à nouveau ses identifiants.</p>
------------------------------------	--

Tableau 13 : Description du cas d'utilisation "Examen de mammographie"

Titre	Établir un diagnostic
Résumé	Une fois connecté, l'acteur consulte la liste des patients à consulter. Il en sélectionne un et établit son diagnostic ainsi de suite.
Acteur	Le radiologue ou l'administrateur
Évènement déclencheur	Un clic
Précondition	Être inscrit en tant que membre du personnel (radiologue) ou administrateur et être connecté.
Scénario nominal	L'acteur charge les images mammaires fournies par le mammographe. Puis, il demande une analyse de ceux-ci à l'aide de notre modèle de VO. Ensuite, il remplit le formulaire d'examen en se basant sur les résultats de notre mode de VO et de son diagnostic. Enfin, il clique sur le bouton enregistrer pour valider son diagnostic.
Scénario alternatif ou contraintes	<p>1) Si l'utilisateur ne remplit pas tous les champs : on lui demande de remplir obligatoirement les champs.</p> <p>2) En cas de souci technique : il est demandé au radiologue de refaire le diagnostic.</p>

3.2. Diagramme de séquence

Le diagramme de séquence est un diagramme d'interaction UML qui modélise les messages transmis entre les participants, comme les objets ou les rôles, ainsi que les structures conditionnelles et de commandes, comme les fragments combinés. Notre attention se porte sur l'authentification du radiologue et la description des séquences se déroulant dans le processus de la réalisation d'une mammographie à la demande d'un professionnel de santé.

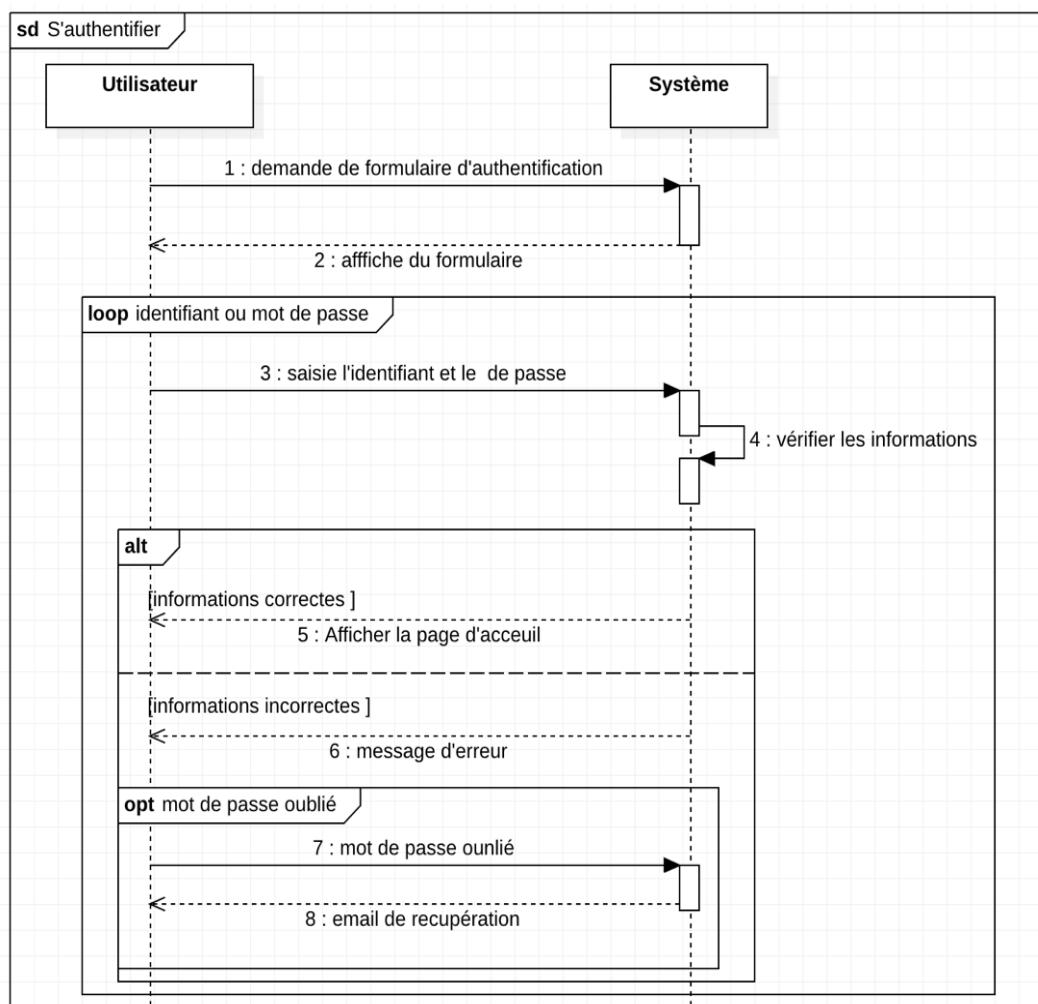


Figure 22 : Diagramme de séquence "Authentification" [3]

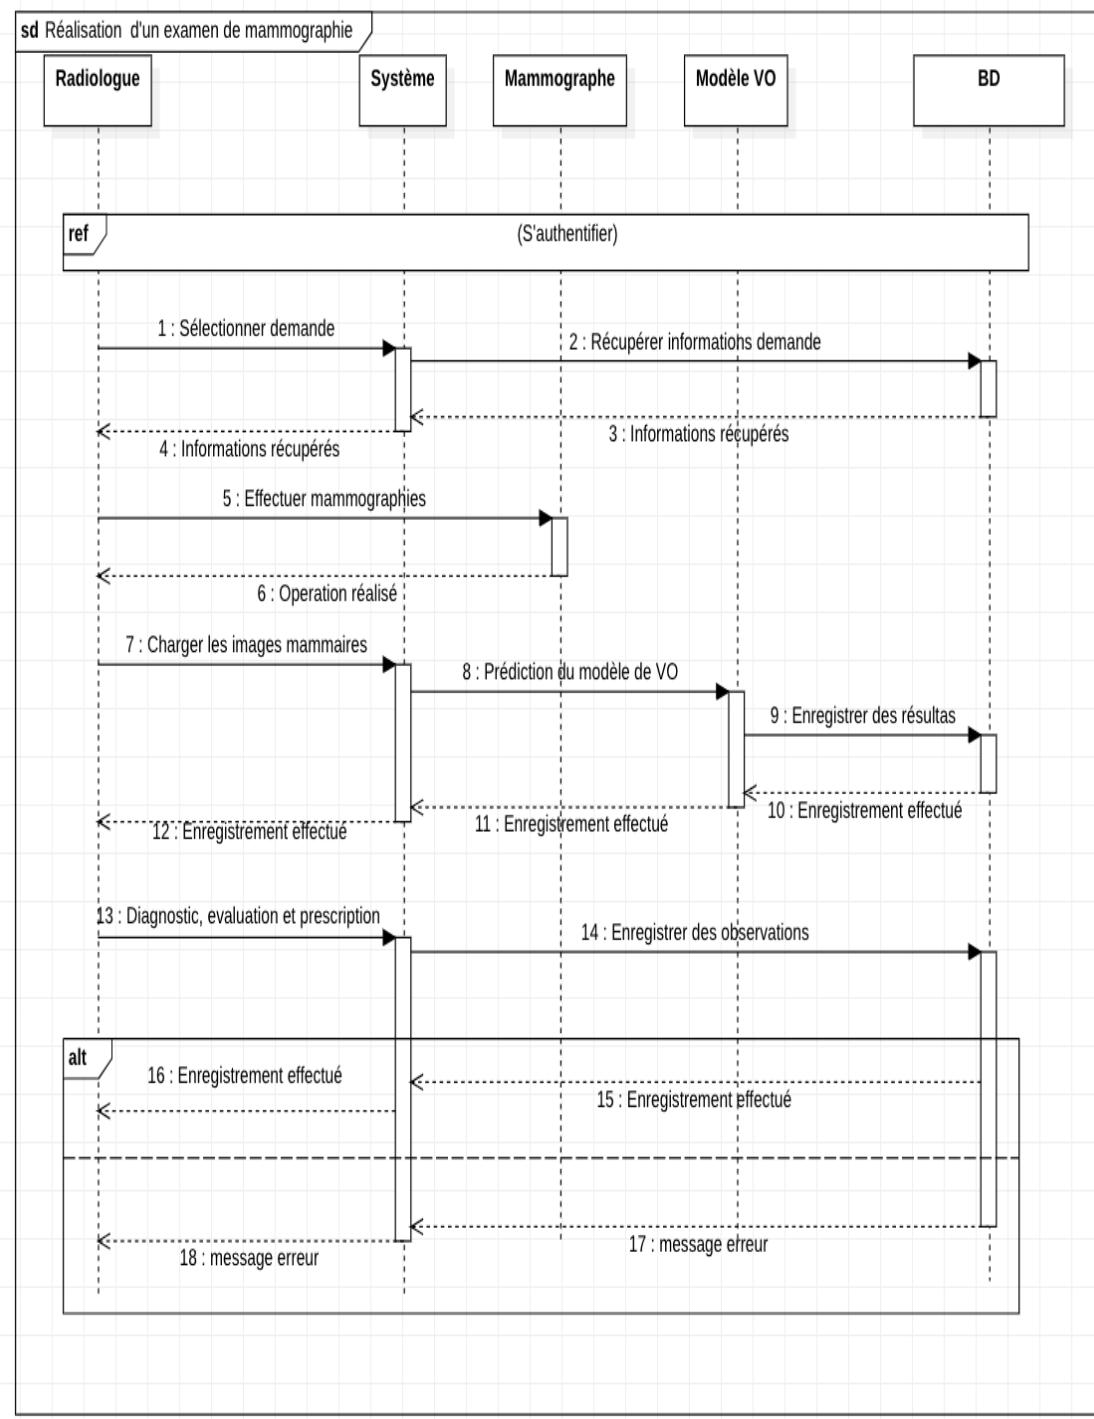


Figure 23 : Diagramme de séquence "Examen de mammographie"

3.3. Diagramme des classes

Notre diagramme des classes représente les différentes classes de notre projet et leurs interactions. Au diagramme des classes existantes composé de 332 classes. Nous avons modifié la classe ExamenRadiologie, qui est reliée à la classe FichePaiement. À partir de là, un professionnel de santé (radiologue) a la possibilité de réaliser un ou plusieurs radiologies, après avoir reçu une demande d'examen en imagerie [3].

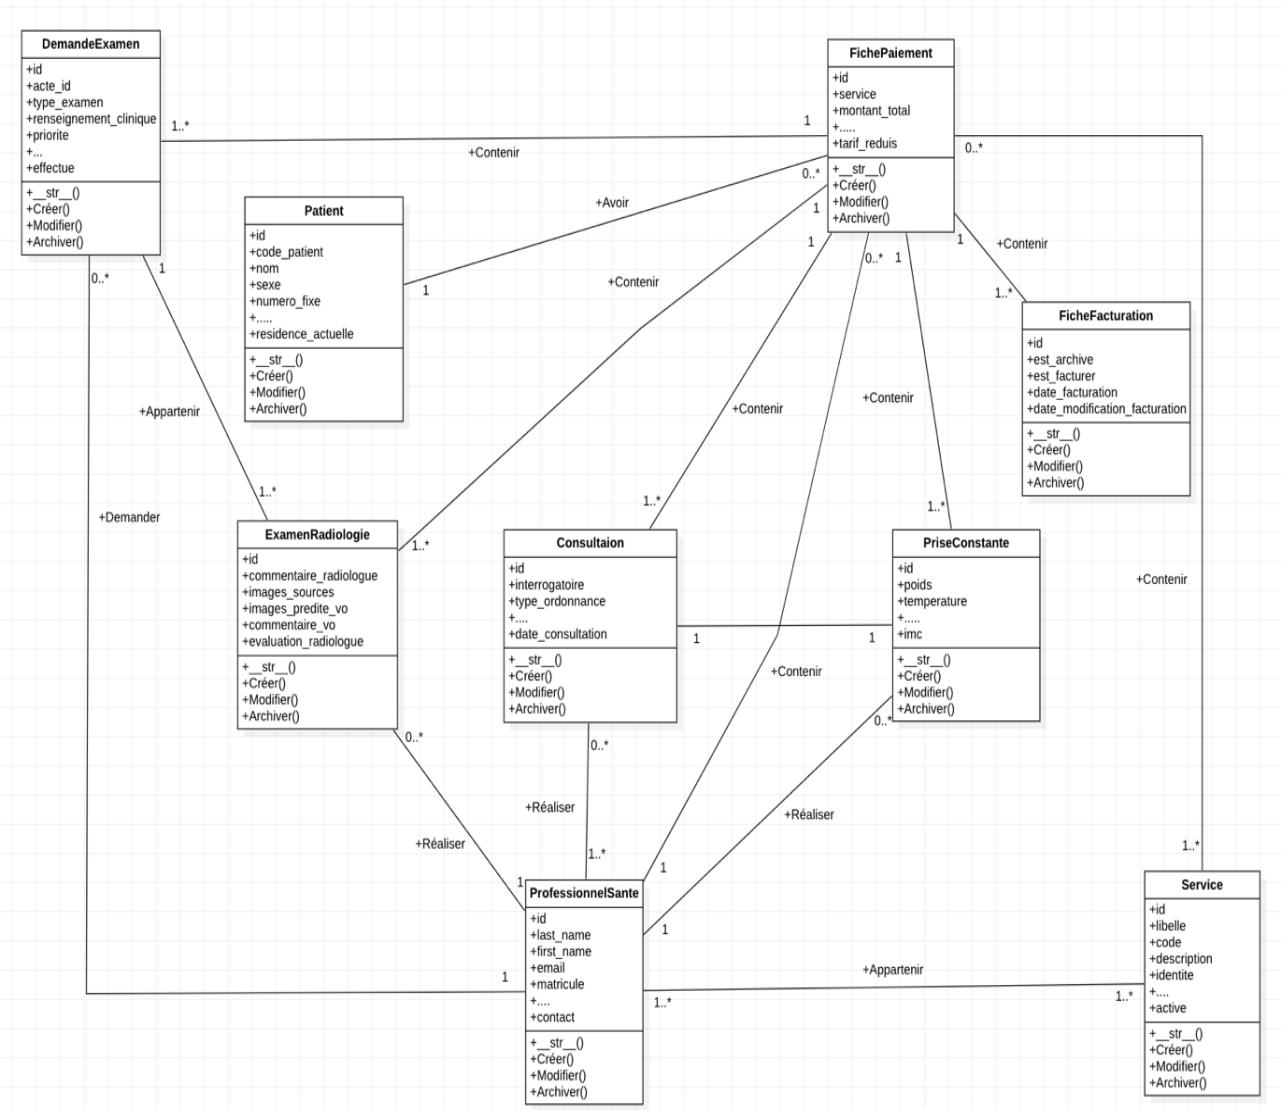


Figure 24 : Diagramme de classes

TROISIÈME PARTIE : RÉSULTATS ET DISCUSSION

Dans cette partie, nous présentons de manière concise nos résultats. Puis, nous les discutons de sorte à les situer dans le contexte scientifique actuel.

CHAPITRE V : RÉSULTATS

I. Outils de développement

1. Environnement de travail

1.1. Matériel utilisé

Ci-après sont présentées les caractéristiques de l'ordinateur portable dont nous disposons durant la réalisation du projet.

Marque



Macbook Pro M1 2020

Caractéristiques

Résolution d'affichage : 1080*1920

Type de disque dur : SSD Capacité

Mémoire vidéo : 16 GB

Processeur : 2,53 GHz

Taille de l'écran : 15,6"

Puce : M1

RAM : 8 GB

Wi-Fi : 2,4 et 5 GHz

1.2. Prérequis logiciel

1.2.1. Système d'exploitation (MacOs)



MacOS est le pilier fondamental du système d'exploitation qui anime chaque Mac, conférant à cet ensemble une vitalité essentielle. Il engendre des possibilités qui seraient inaccessibles sur d'autres plateformes informatiques, grâce à sa conception profondément adaptée à l'architecture matérielle qui le soutient, et réciproquement.

1.2.2. Éditeur de code

L'on a eu à utiliser deux logiciels pour le développement de notre solution, Jupiter Notebook et Colab pour la réalisation du modèle d'apprentissage automatique, puis VS Code pour la conception de l'application web.

Tableau 14 : Éditeur de code

Éditeur de code	Description
	Jupyter Notebook est une application Web open source qui vous permet de créer et de partager des documents contenant du code en direct, des équations, des visualisations et du texte narratif.
	Visual Studio Code est un éditeur de code source léger, mais puissant qui s'exécute sur votre bureau et est disponible pour Windows, macOS et Linux.
	Colaboratory, souvent raccourci en "Colab", vous permet d'écrire et d'exécuter du code Python dans votre navigateur. Pour notre projet, nous avons suscrit à des abonnements colab pro + offrant des GPU (A100, V100 et T4), TPU et 500 unités de calcul.

2. Outils et technologies utilisés

Dans les éditeurs de textes utilisés, l'on a implémenté plusieurs langages de programmation, des librairies et une base de données qui nous ont permis d'atteindre nos objectifs et de proposer une application web performante basée sur modèle de VO.

2.1. Langage de développement

Un langage de programmation consiste à formuler des algorithmes et produire des programmes informatiques. Ceux implémentés dans notre projet sont cités ci-dessous.

Tableau 15 : Langage de développement

Langage de développement	Description
	Python est un langage de programmation interprété, orienté objet, de haut niveau avec une sémantique dynamique. Notre modèle de VO est entièrement réalisé en python pour sa performance, sa vaste communauté (très dynamique) et ses syntaxes simples.
	React est une bibliothèque JavaScript libre développée par Facebook depuis 2013. Le but principal de ce langage est de faciliter la création d'application web monopage. L'on utilise pour la conception de notre interface.
	Django est un framework Web Python de haut niveau qui encourage un développement rapide et une conception propre et pragmatique. Cet outil intervient dans la réalisation des API interagissant avec notre base de données et l'interface web.

2.2. Librairie

Une bibliothèque désigne un recueil de fonctions et de classes préalablement codées dans un langage spécifique, à partir desquelles nous sélectionnons les fonctions et les classes requises. Les bibliothèques utilisées dans notre projet sont répertoriées dans le tableau ci-dessous, offrant ainsi une vue exhaustive.

Tableau 16 : Librairie

Rôle	Librairie
Analyse et visualisation des données	Pandas, matplotlib, seaborn, numpy, cv2 et pil
Traitement de données	Albumentations, sklearn, torch, cv2, pil et pydicom
Conception, sélection et validation du modèle	Pytorch et Timm
Évaluation des performances du modèle	Torch et sklearn

2.3. Base de données



PostgreSQL est une puissante base de données relationnelle objet open source. Il est réputé pour sa fiabilité, sa robustesse et ses performances. Il fournit le stockage de nos données.

II. Présentation des résultats

1. Application web

L’application web intégrée au logiciel DPI est répartie sur plusieurs pages. Elle conserve la charte graphique du DPI.

1.1. Page de connexion

Cette page de connexion est la porte d'accès aux examens d'imagerie. Le radiologue doit entrer des identifiants corrects pour passer la porte.

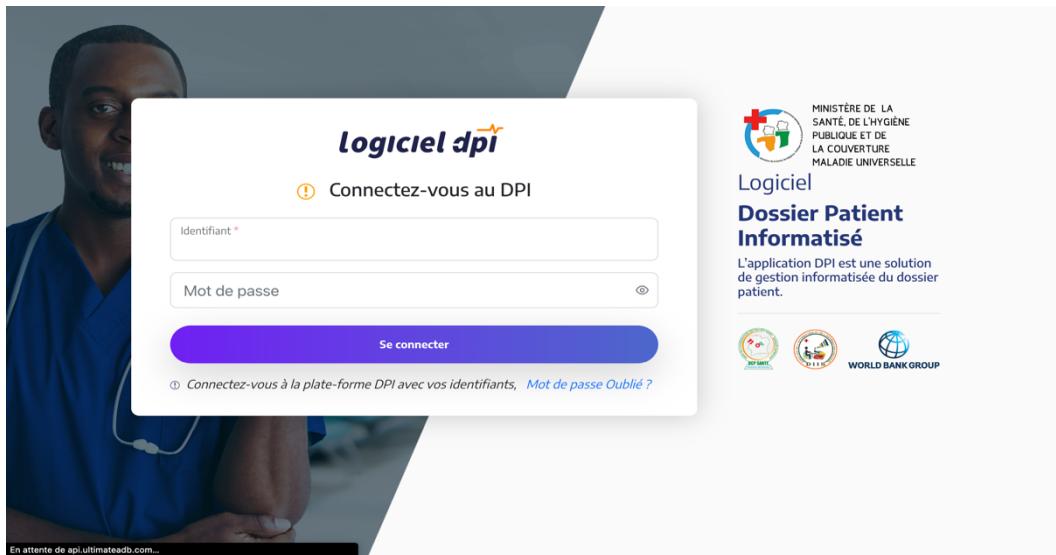


Figure 25 : Page de connexion

1.2. Page d'accueil

Elle s'ouvre en affichant la liste des demandes d'examens à réaliser. À cette liste, elle joint des options permettant de réaliser diverses opérations (faire des examens et afficher les examens demandés par le médecin référent).

A screenshot of the Logiciel dpi home page. The left sidebar shows a navigation menu with icons for "Tableau de bord", "Demandes examens" (selected), and "Résultats examens". The main content area is titled "RADIOLOGIE |". It displays a table titled "Liste des demandes d'examens" with columns: "Code Patient ↑↓", "Patient ↑↓", "Service ↑↓", "Medecin Requerant ↑↓", "Date De La Demande ↑↓", and "Action". There are six rows in the table, each with a blue "les" button. A search bar at the top right says "Rechercher un patient". The top navigation bar includes "Accueil", "Logiciel", "Hi, admin", and a dropdown menu.

Figure 26 : Page d'accueil

1.3. Page de diagnostic par la VO

Sur cette page, le radiologue charge les résultats des mammographies. Puis enclenche la détection des tumeurs par notre mode de VO. Il peut effectuer 50 analyses simultanées en moins de cinq minutes.

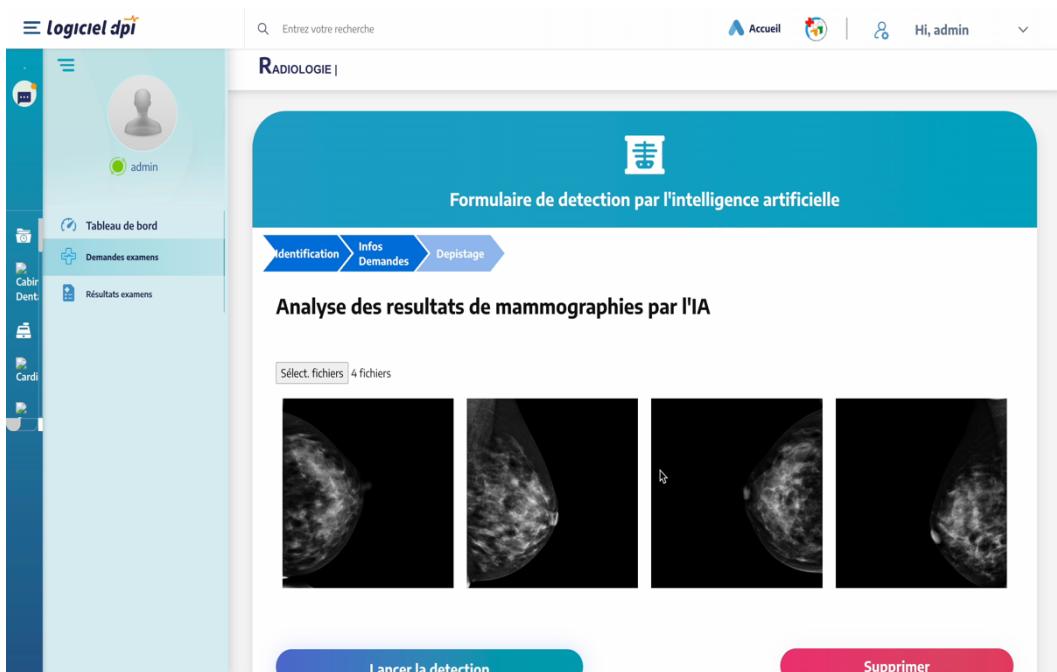


Figure 27 : Page de diagnostic par la VO

1.4. Page de diagnostic du radiologue

Cette page permet au radiologue d'établir son diagnostic, puis d'évaluer notre intelligence artificielle. L'on observe la présence d'une tumeur dans les images (figure 28 et figure 29), notre modèle la détecte avec une précision moyenne de 94%. Puis une observation de notre modèle est faite au sein de la figure 31, disant une biopsie doit-être réaliser pour déterminer la nature des tumeurs (bénigne ou maligne) détectées.

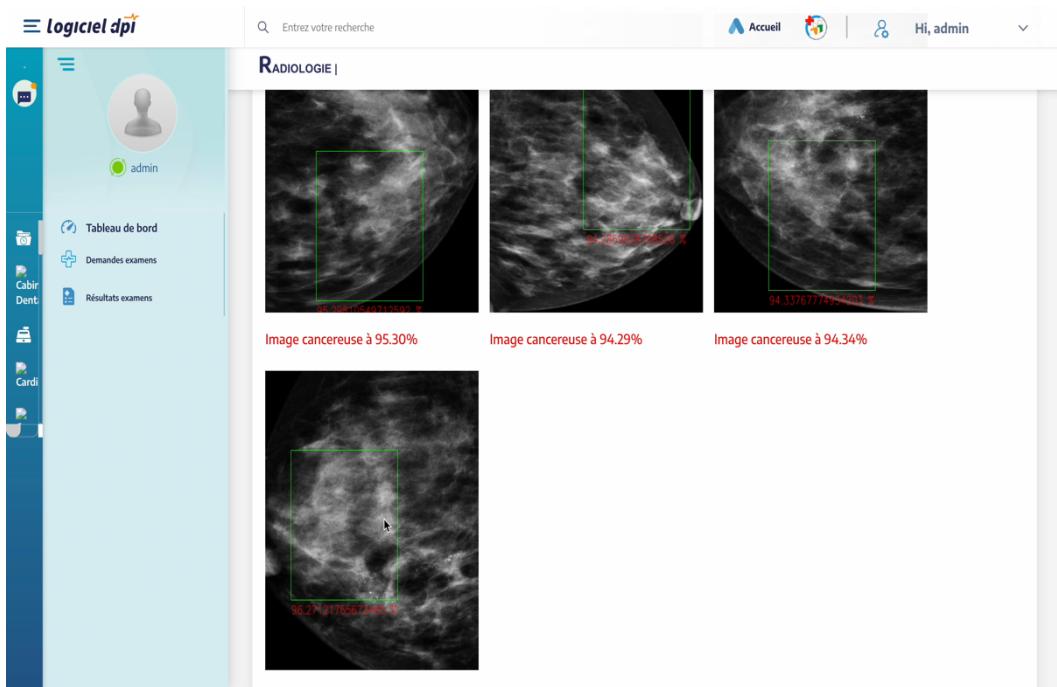


Figure 28 : Page de diagnostic du radiologue 1

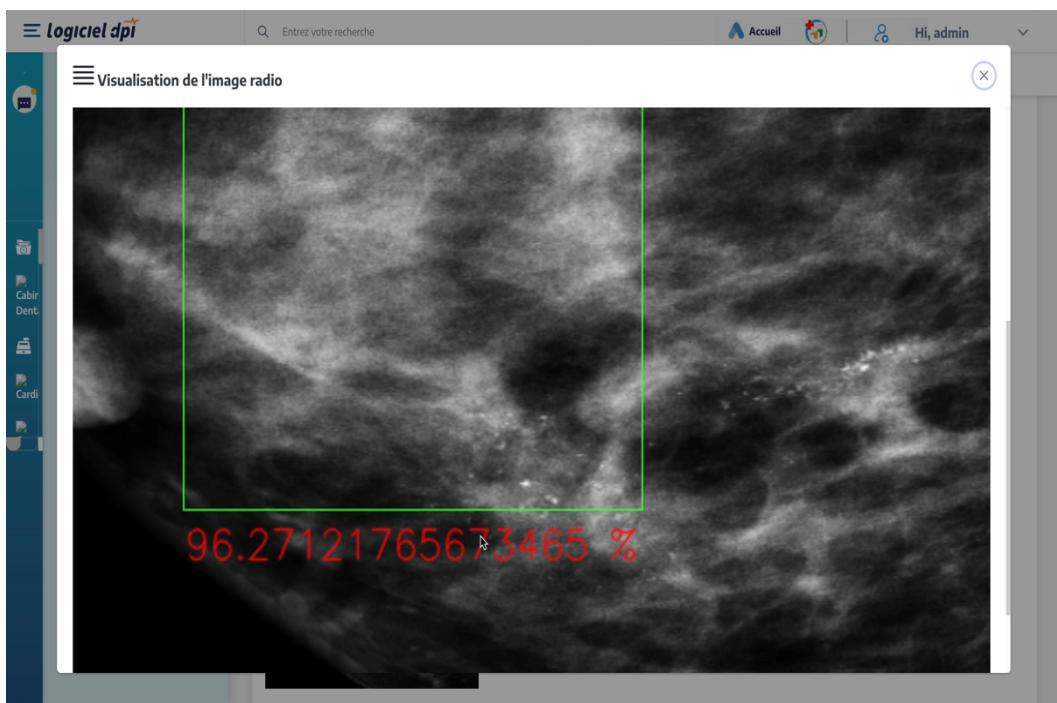


Figure 29 : Visualisation d'un résultat du modèle de VO

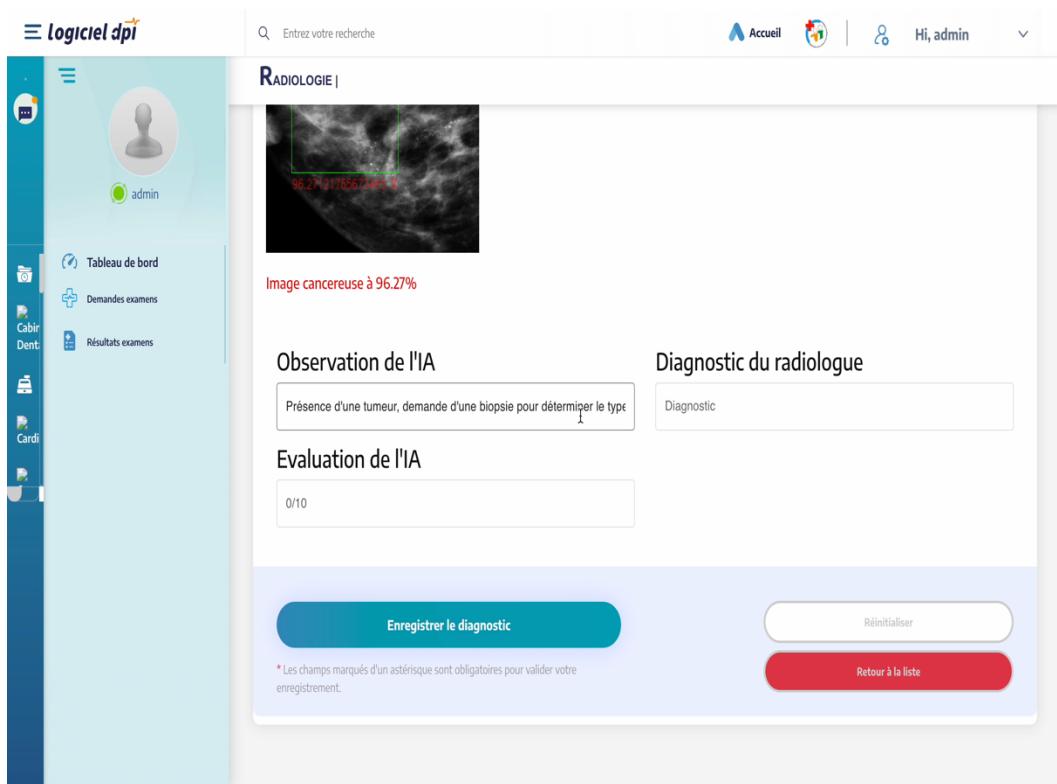


Figure 30 : Page de diagnostic du radiologue 2

2. Modèle de VO

Le tableau 14 présente les scores AUC-ROC de nos différentes approches, en fonction de la dimension de l'image d'entrée. Le modèle combinant l'EfficientNetV2 plus nos couches d'attention performe mieux sur nos données. Cette performance est de 85% pour un taux de faux positifs de 50% la plus élevée pour les images dimension 600*600 dans un ensemble de données de contenant 1250 images mammographiques dont 291 cancéreuses et 959 images.

Tableau 17 : Résultats du modèle de VO

Dimension	Modèle	Score AUC-ROC (ensemble d'entraînements, figure 45)	Score AUC-ROC (ensemble de tests)
384*384	EfficientNetV2	0,67	0,62
	EfficientNetV2 + Couche d'auto attention	0,70	0,68
512*512	EfficientNetV2	0,75	0,70
	EfficientNetV2 + Couche d'auto attention	0,85	0,80
600*600	EfficientNetV2	0,80	0,72
	EfficientNetV2 + Couche d'auto attention	0,89	0,85

CHAPITRE VI : DISCUSSION DES RÉSULTATS ET COÛT DU PROJET

I. Discussion des résultats

En analysant les résultats observés dans le tableau 14, il est concluant d'affirmer que l'augmentation de la dimension des images et l'intégration d'une couche d'attention représentent des approches pertinentes. Ils améliorent les performances des modèles de classification exploitant EfficientNetV2. Toutefois, ces résultats peuvent être encore améliorés, nous pouvons :

- augmenter la taille de nos images ;
- customiser les paramètres de notre modèle ;
- et élargir notre jeu de données qui est de 25000 images mammographiques.

II. Coût du projet

L'évaluation budgétaire est une démarche visant à estimer les dépenses anticipées nécessaires à la concrétisation d'un projet. À cet égard, le tableau ci-joint illustre notre estimation financière.

Tableau 18 : Estimation financière du projet

Numéro	Désignation	Quantité	Prix unitaire	Prix total
1	Macbook Pro M1 2020	1	935 000	935 000
2	Communication et internet	6	50 000	600 000
3	Abonnement Colab pro+	10	32 850	328 500
4	Abonnement Google drive (200giga)	6	2650	15 900
5	Main d'œuvre (6 mois)	6	500 000	3 000 000
				4 879 400

CONCLUSION

La conception d'un système d'aide intégré pour la détection du cancer du sein dans un ERP utilisant des réseaux de neurones : cas du dossier patient informatisé (DPI) est la thématique sur laquelle nous avons travaillé tout au long de nos cinq mois de stage. Cette conception consiste à faciliter la détection des tumeurs au sein des images de mammographies. Cette étude s'inscrit dans une démarche visant à apporter des améliorations substantielles dans le domaine des soins de santé, à optimiser l'utilisation des ressources médicales et à contribuer de manière significative à la recherche médicale. Le problème central qui en découle est comment concevoir et intégrer un dispositif d'assistance pour le dépistage du cancer du sein au sein d'un DPI, de façon à rationaliser le processus de prise en charge des patients de manière optimale ? Pour résoudre cette problématique, nous choisissons d'adopter des architectures utilisant des modèles pré-entraînés basés sur des réseaux de neurones convolutifs pour l'extraction des caractéristiques au sein des images. Ensuite, nous complétons ces architectures en ajoutant des couches d'auto-attention, une couche de sortie suivie d'une carte d'activation de classe pondérée par le gradient.

Cette méthodologie d'analyse suivie a produit les résultats escomptés. Notre solution se présente sous forme d'une application web intégrée au logiciel DPI, permettant aux radiologues d'effectuer le dépistage du cancer après avoir chargé des images mammaires produites par un mammographe. Puis, les résultats du diagnostic fournis par le modèle de VO sur la base des images entrées en arrière-plan, sont par la suite envoyés aux radiologues. Ce qui lui permet de délivrer un meilleur diagnostic et d'optimiser le temps de traitement lors de la prise en charge de ce dernier.

Cette solution s'avère pertinente et originale, car le taux de vrais positifs est supérieur à 80% pour un taux de faux positifs supérieur à 20% sur des images de dimension 600*600 pixels dans un jeu de données de contenant 1250 images dont 291 cancéreuses et 959 images [8]. Cependant, l'on peut l'améliorer. Une première

perspective consiste à améliorer le taux de vrais positifs de notre modèle de détection du cancer du sein, dans le but de passer de 80 % à 99 % pour un taux de faux positifs de 5% sur un ensemble de tests d'au moins 291 images cancéreuses et 959 images saines. Ensuite, nous visons à obtenir l'approbation du Centre National d'Oncologie Médicale et de Radiothérapie Alassane Ouattara (CNRAO) afin d'accéder à leurs données de mammographies. Cette approbation nous permettra de réaliser un apprentissage par transfert (figure 43, annexe B), adaptant ainsi notre solution aux données du CNRAO. Suite à cette mise à jour, notre intention est de faire homologuer notre solution par le corps médical pour la déployer dans des centres de mammographies. De plus, nous comptons orienter notre axe d'étude sur la détection d'autres cas de cancers tels que celui du poumon, de la prostate et du cerveau à l'aide de l'intelligence artificielle.

BIBLIOGRAPHIE

- [1] **Globocan**, disponible sur <https://gco.iarc.fr/today/data-sources-methods>, consulté le 28-02-2023.
- [2] Le Ministère de la Santé, de l'Hygiène Publique et de la Couverture Maladie Universelle en Côte d'Ivoire, **Plan stratégique national de lutte contre le cancer 2022-2025**, 2020.
- [3] T. Z. Abasse, **Mise en place d'une application web de gestion de clinique privée : la Grande Clinique du Dokui**, Ecole Supérieure Africaine des Technologies de l'Information et de la Communication, 2020.
- [4] **Interprétation des résultats d'une mammographie**, disponible sur <https://www.roche.be/fr/patients/maladies/cancer-du-sein/comprendre.html>, consulté le 05-03-2023.
- [5] **Morphologie du sein**, disponible sur <https://www.passeportsante.net/fr/parties-corps/Fiche.aspx?doc=sein>, consulté le 14-02-2023.
- [6] **Présentation du cancer du sein**, disponible sur <https://www.roche.be/fr/patients/maladies/cancer-du-sein/comprendre.html>, consulté le 17-02-2023.
- [7] P. K. Ghislain, **Réduction du bruit dans les images mammaires fondée sur des processus de diffusion**, Institut National Polytechnique Félix Houphouët Boigny de Yamoussoukro, 2018.
- [8] **Intelligence artificielle et imagerie médicale**, disponible sur <https://travaux.master.utc.fr/wp-content/uploads/sites/16/2022/01/intelligence-artificielle-et-imagerie-medicale-version-finale.pdf>, consulté le 12-02-2023.
- [9] R. Agarwal, O. Diaz, X. Lladó, M. H. Yap et R. Martí, **Automatic mass detection in mammograms using deep convolutional neural networks**, Journal of Medical Imaging, 2019.
- [10] K. H. Cha, N. Petrick, A. Pezeshk, C. G. Graff, D. Sharma, A. Badal et B. Sahiner, **Evaluation of data augmentation via synthetic images for improved breast mass detection on mammograms using deep learning**, Journal of Medical Imaging, 2019.

- [11] Gupta, S. Anuj Kumar et Bhupendra, **A Novel Approach for Breast Cancer Detection and Segmentation in a Mammogram**, Department of Computer Science & Engineering PDPM-IIITDM Jabalpur, 2015.
- [12] I. Y. G. Khang et T. Fei, **On the classification of simple and complex biological images using Krawtchouk moments and Generalized pseudo-Zernike moments: a case study with fly wing images and breast cancer mammograms**, Universiti Malaya, 2021.
- [13] F. G. Farhat, **A study of machine learning and deep learning models for solving medical imaging problems**, New Jersey Institute of Technology, New Jersey Institute of Technology, 2019.
- [14] L. Alzubaidi, J. Zhang, A. J. Humaidi, A. Al-Dujaili, Y. Duan, O. Al-Shamma, J. Santamaría, M. A. Fadhel et M. A. a. L. Farhan, **Review of deep learning: concepts, CNN architectures, challenges, applications, future directions**, Journal of Big Data, 2021.
- [15] T. A. Jacob, **Traduction automatisée des langues Africaines Cas du lingala**, International Data Science Institute, International Data Science Institute - Institut National Polytechnique Félix Houphouët Boigny de Yamoussoukro, 2020.
- [16] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell et S. Xie, **A ConvNet for the 2020s**, Facebook AI Research (FAIR) -UC Berkeley, 2022.
- [17] A. Dosovitskiy, L. Beyer et A. Kolesnikov, **An image is worth 16x16 words: transformers for image recognition at scale**, Google Research, Brain Team, 2021.
- [18] M. Tan et Q. V. Le, **EfficientNetV2 : Smaller Models and Faster Training**, 2021.
- [19] M. Tan et Q. V. Le, **EfficientNet : Rethinking Model Scaling for Convolutional Neural Networks**, 2019.
- [20] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez et L. K. a. I. Polosukhin, **Attention Is All You Need**, 2017.
- [21] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam et D. P. a. D. Batra, **Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization**, 2019.

[22] D. Souleymane, **Mise en œuvre d'un module d'anamnèse médical basé sur un modèle d'apprentissage automatique (AA) : Cas du service médecine général de la Grande Clinique de Dokui**, Ecole Supérieure Africaine des Technologies de l'Information et de la Communication (ESATIC), 2021

ANNEXE

Annexe A : Cancer du sein

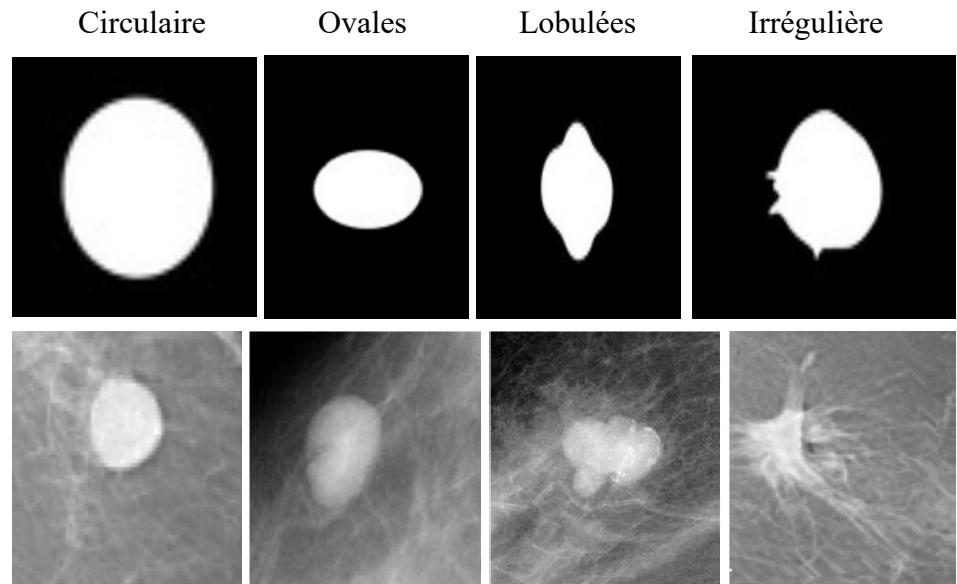


Figure 31 : Formes des masses mammaires

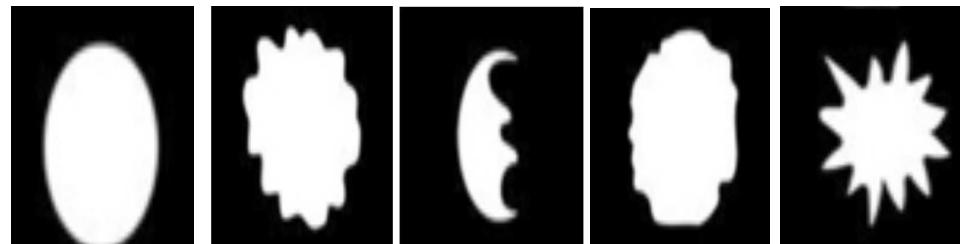


Figure 32 : Contours des masses

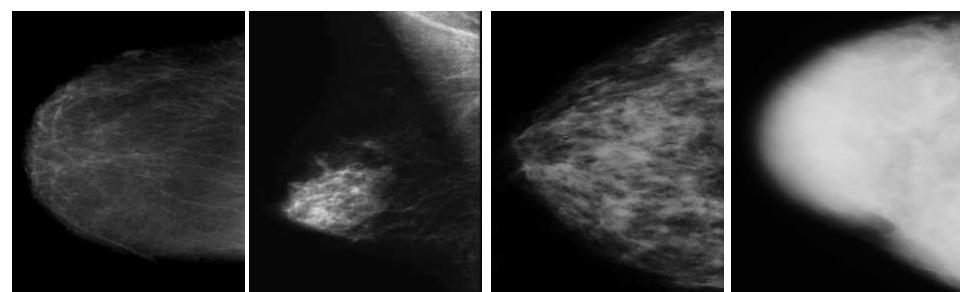


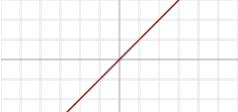
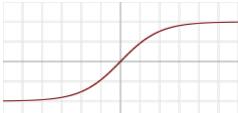
Figure 33 : Représentation de la catégorisation de la densité mammaire



Figure 34 : Mammographe analogique Lilyum

Annexe B : Vision par ordinateur

Tableau 19 : Quelques fonctions d'activations

Fonction d'activation	Courbe	Équation, $f(x)$
Linéaire		x
Binaire		$\begin{cases} 0 & \text{if } x < 0 \\ 1 & \text{if } x \geq 0 \end{cases}$
Sigmoïde		$\sigma(x) \doteq \frac{1}{1 + e^{-x}}$
TanH		$\tanh(x) \doteq \frac{e^x - e^{-x}}{e^x + e^{-x}}$
ReLU		$(x)^+ \doteq \begin{cases} 0 & \text{if } x \leq 0 \\ x & \text{if } x > 0 \end{cases} = \max(0, x) = x \mathbf{1}_{x>0}$
Leaky ReLU		$\begin{cases} 0.01x & \text{if } x < 0 \\ x & \text{if } x \geq 0 \end{cases}$
Softmax		$\frac{e^{x_i}}{\sum_{j=1}^J e^{x_j}}$ for $i = 1, \dots, J$

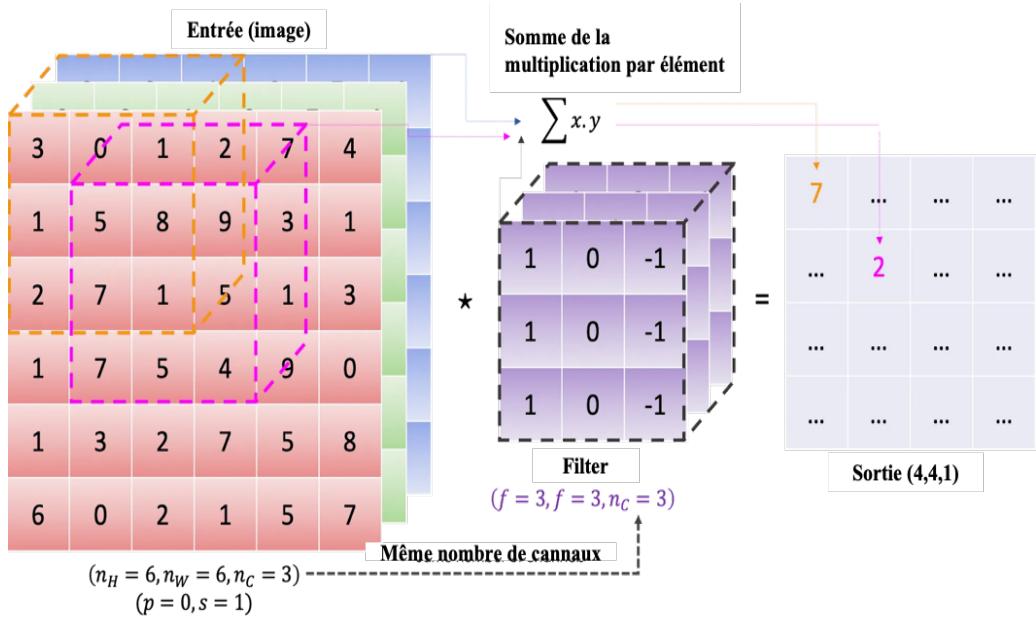


Figure 35 : Opération de convolution

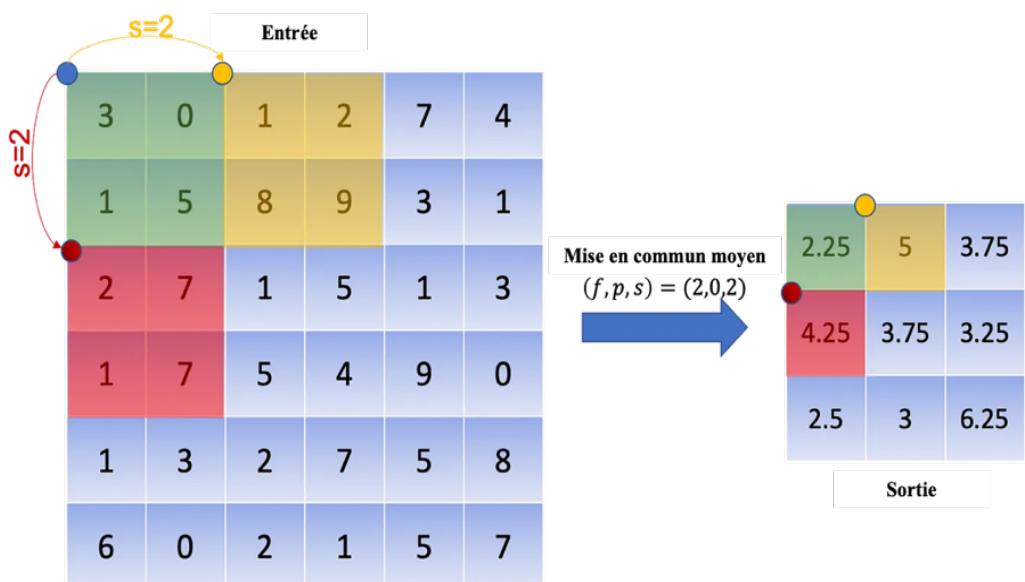


Figure 36 : Mise en commun moyen

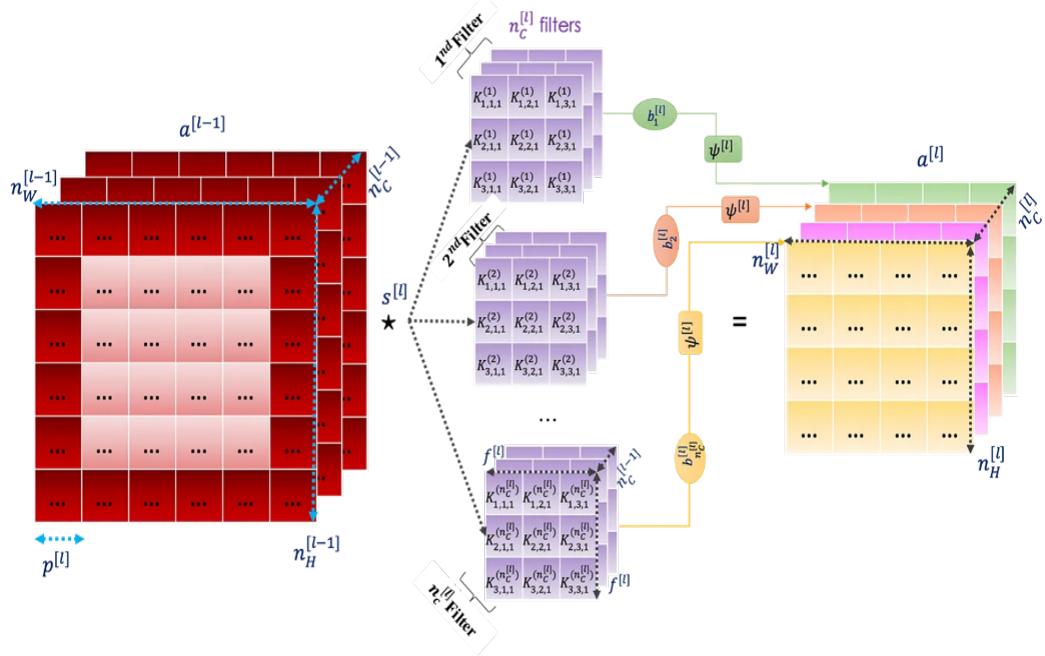


Figure 37 : Couche de convolution

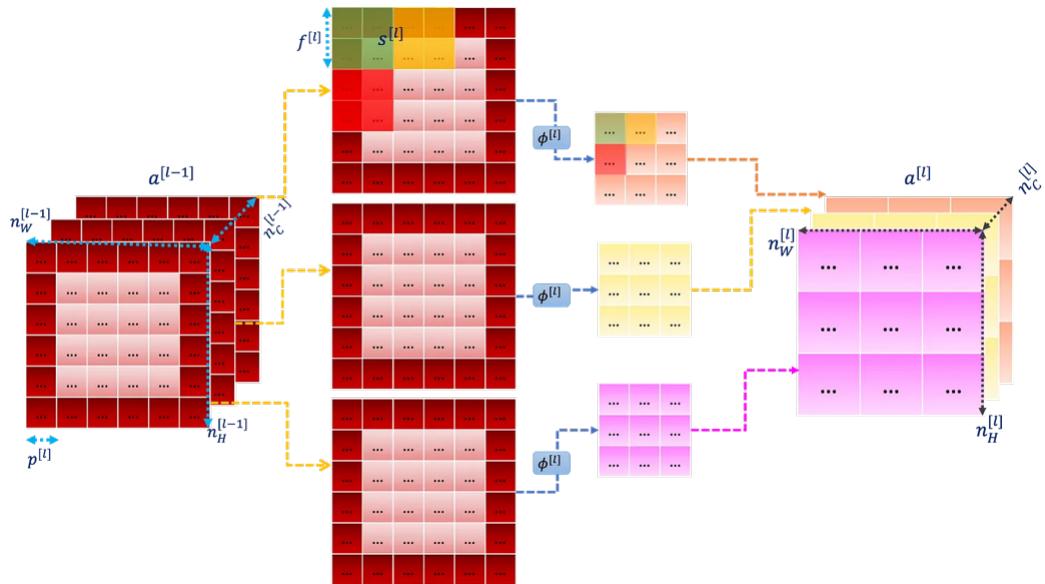


Figure 38 : Couche de mise en commun

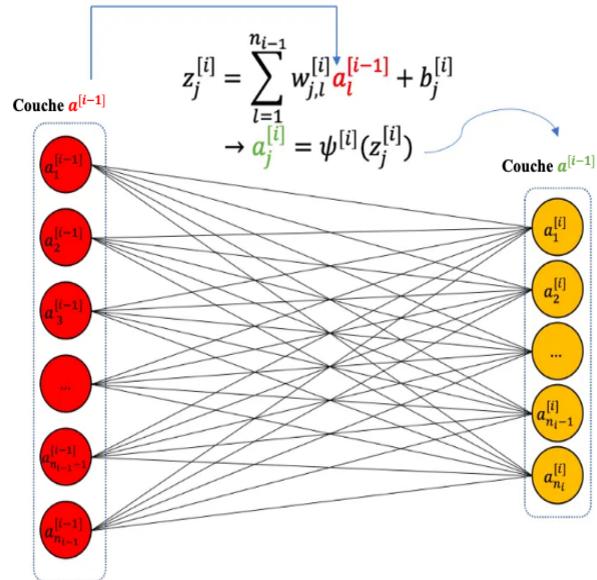


Figure 39 : Couche entièrement connectée

Transfer Learning

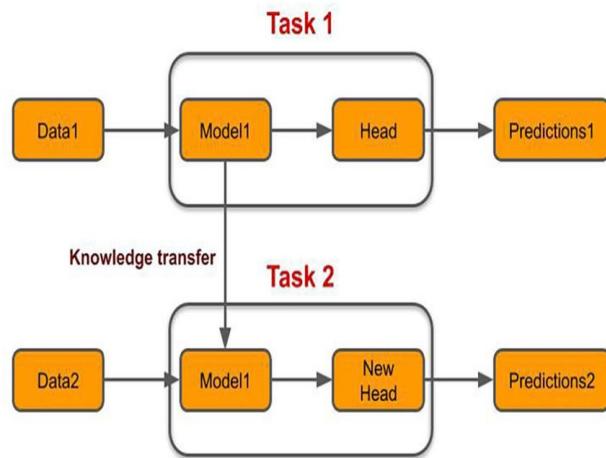


Figure 40 : Apprentissage par transfert

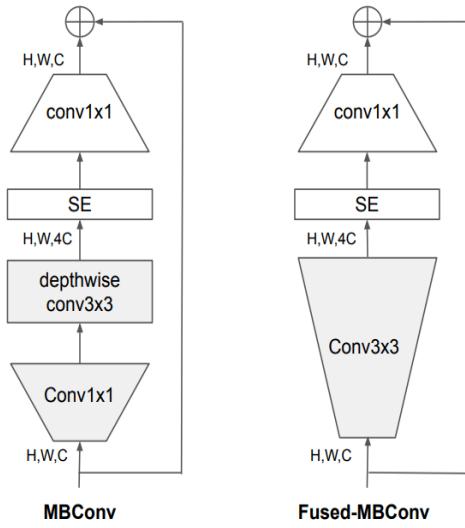


Figure 41 : Structure de MBConv et Fused-MBConv

```

INFO: [500/521] Data 0.140 (0.119) Elapsed 0m 33s (remain 0m 53s) Loss: 0.6298(0.6419)
EVAL: [200/521] Data 0.140 (0.119) Elapsed 0m 33s (remain 0m 53s) Loss: 0.6298(0.6419)
EVAL: [300/521] Data 0.000 (0.119) Elapsed 0m 50s (remain 0m 36s) Loss: 0.6815(0.6453)
EVAL: [400/521] Data 0.000 (0.119) Elapsed 1m 6s (remain 0m 20s) Loss: 0.6615(0.6474)
EVAL: [500/521] Data 0.000 (0.118) Elapsed 1m 23s (remain 0m 3s) Loss: 0.6298(0.6462)
Epoch 4 - avg_train_loss: 0.6494 avg_val_loss: 0.6463 time: 671s
INFO: __main__:Epoch 4 - avg_train_loss: 0.6494 avg_val_loss: 0.6463 time: 671s
Epoch 4 - Score: 0.8921 Scores: [0.8921]
INFO: __main__:Epoch 4 - Score: 0.8921 Scores: [0.8921]
Epoch 4 - Save Best Loss: 0.6463 Model
INFO: __main__:Epoch 4 - Save Best Loss: 0.6463 Model
EVAL: [520/521] Data 0.000 (0.118) Elapsed 1m 26s (remain 0m 0s) Loss: 0.6552(0.6463)
Epoch: [5][0/1562] Data 0.700 (0.700) Elapsed 0m 0s (remain 22m 59s) Loss: 0.6931(0.6931) Grad: 0.94
Epoch: [5][100/1562] Data 0.065 (0.229) Elapsed 0m 39s (remain 9m 35s) Loss: 0.6615(0.6483) Grad: 0.
Epoch: [5][200/1562] Data 0.455 (0.212) Elapsed 1m 15s (remain 8m 32s) Loss: 0.6298(0.6495) Grad: 0.
Epoch: [5][300/1562] Data 0.000 (0.199) Elapsed 1m 49s (remain 7m 40s) Loss: 0.7132(0.6476) Grad: 0.
Epoch: [5][400/1562] Data 0.697 (0.203) Elapsed 2m 27s (remain 7m 8s) Loss: 0.5349(0.6466) Grad: 1.2
Epoch: [5][500/1562] Data 0.347 (0.207) Elapsed 3m 6s (remain 6m 34s) Loss: 0.6298(0.6460) Grad: 11.
Epoch: [5][600/1562] Data 0.085 (0.207) Elapsed 3m 44s (remain 5m 58s) Loss: 0.6298(0.6471) Grad: 0.
Epoch: [5][700/1562] Data 0.204 (0.207) Elapsed 4m 21s (remain 5m 20s) Loss: 0.5982(0.6477) Grad: 0.
Epoch: [5][800/1562] Data 0.000 (0.207) Elapsed 4m 58s (remain 4m 43s) Loss: 0.6615(0.6480) Grad: 0.
Epoch: [5][900/1562] Data 0.000 (0.206) Elapsed 5m 34s (remain 4m 5s) Loss: 0.5665(0.6477) Grad: 0.8
Epoch: [5][1000/1562] Data 0.254 (0.206) Elapsed 6m 11s (remain 3m 28s) Loss: 0.6615(0.6471) Grad: 0.
Epoch: [5][1100/1562] Data 0.000 (0.206) Elapsed 6m 49s (remain 2m 51s) Loss: 0.5349(0.6466) Grad: 0.
Epoch: [5][1200/1562] Data 0.552 (0.207) Elapsed 7m 27s (remain 2m 14s) Loss: 0.6931(0.6464) Grad: 0.
Epoch: [5][1300/1562] Data 0.394 (0.206) Elapsed 8m 3s (remain 1m 36s) Loss: 0.7132(0.6464) Grad: 0.
Epoch: [5][1400/1562] Data 0.000 (0.206) Elapsed 8m 40s (remain 0m 59s) Loss: 0.6615(0.6463) Grad: 0.
Epoch: [5][1500/1562] Data 0.000 (0.206) Elapsed 9m 18s (remain 0m 22s) Loss: 0.6815(0.6467) Grad: 0.
Epoch: [5][1561/1562] Data 0.337 (0.205) Elapsed 9m 39s (remain 0m 0s) Loss: 0.6298(0.6463) Grad: 0.
EVAL: [0/521] Data 0.494 (0.494) Elapsed 0m 0s (remain 4m 51s) Loss: 0.6615(0.6615)
EVAL: [100/521] Data 0.239 (0.122) Elapsed 0m 17s (remain 1m 11s) Loss: 0.6298(0.6490)
EVAL: [200/521] Data 0.252 (0.119) Elapsed 0m 33s (remain 0m 53s) Loss: 0.6298(0.6447)
EVAL: [300/521] Data 0.088 (0.118) Elapsed 0m 50s (remain 0m 36s) Loss: 0.6815(0.6478)
EVAL: [400/521] Data 0.000 (0.117) Elapsed 1m 6s (remain 0m 19s) Loss: 0.6615(0.6503)
EVAL: [500/521] Data 0.000 (0.118) Elapsed 1m 23s (remain 0m 3s) Loss: 0.6298(0.6489)
Epoch 5 - avg_train_loss: 0.6463 avg_val_loss: 0.6491 time: 666s
INFO: __main__:Epoch 5 - avg_train_loss: 0.6463 avg_val_loss: 0.6491 time: 666s
Epoch 5 - Score: 0.8762 Scores: [0.8762]
INFO: __main__:Epoch 5 - Score: 0.8762 Scores: [0.8762]
EVAL: [520/521] Data 0.000 (0.118) Elapsed 1m 26s (remain 0m 0s) Loss: 0.6552(0.6491)
===== fold: 1 result =====
INFO: __main__:===== fold: 1 result =====
Score: 0.8921 Scores: [0.8921]
INFO: __main__:Score: 0.8921 Scores: [0.8921]

```

Figure 42 : Entraînement du modèle

Annexe C : Méthode et langage de modélisation

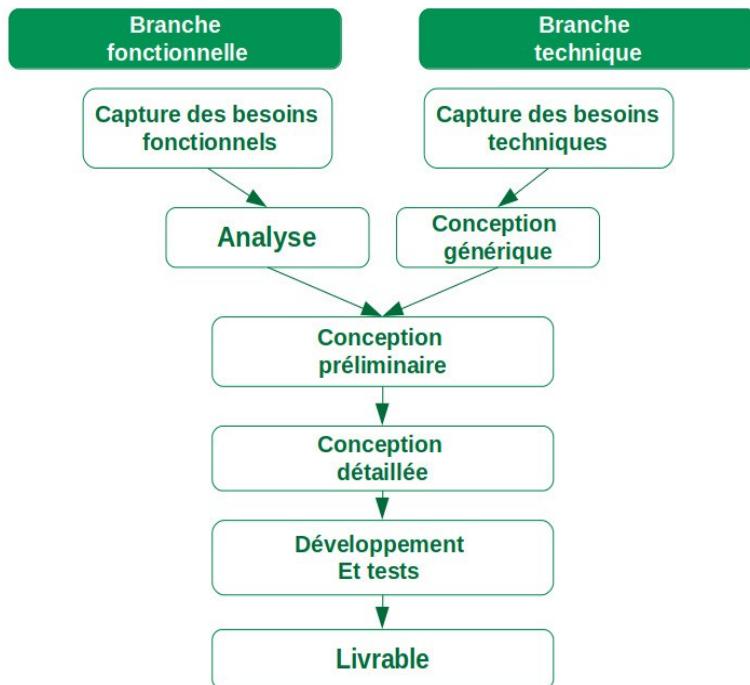


Figure 43 : Méthode 2TUP

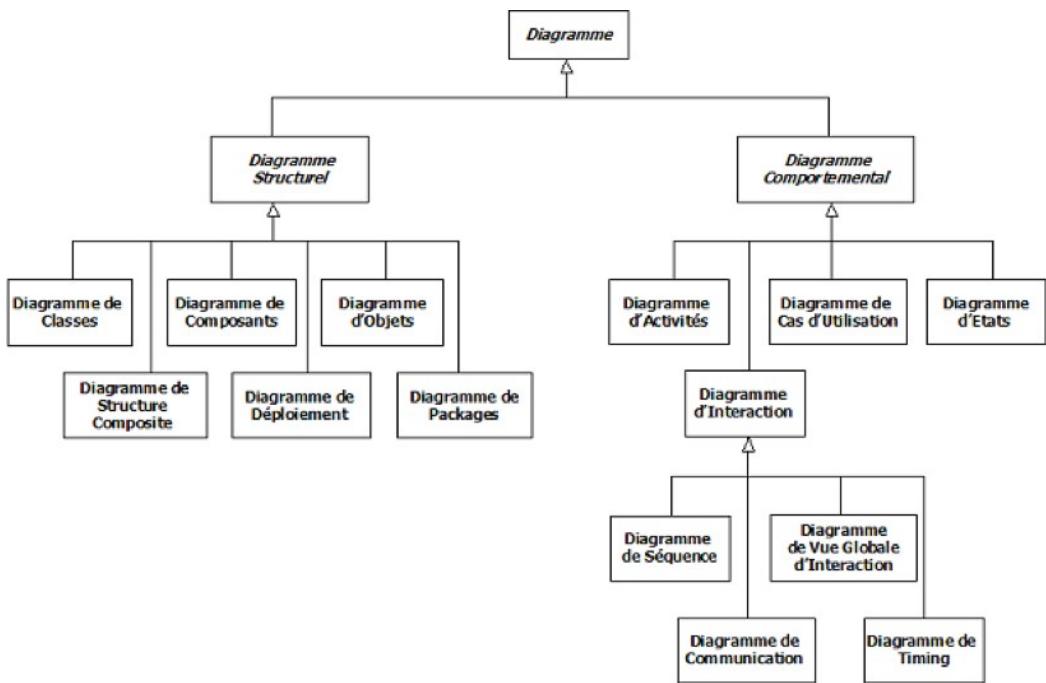


Figure 44 : Organigramme des diagrammes UML

TABLE DES MATIERES

DÉDICACE.....	i
RÉMERCIEMENTS	ii
SOMMAIRE	iii
LISTE DES SIGLES ET ABRÉVIATIONS	v
GLOSSAIRE.....	vi
LISTE DES FIGURES.....	viii
LISTE DES TABLEAUX.....	x
INTRODUCTION.....	1
PRÉMIÈRE PARTIE : GÉNÉRALITÉS.....	3
CHAPITRE I : CADRE ET CONTEXTE DE TRAVAIL.....	4
I. Présentation de la structure d'accueil	4
1. Historique.....	4
2. Structure d'accueil	4
3. Secteurs d'activités et services proposés.....	5
3.1. Secteurs d'activités.....	5
3.2. Services proposés	6
II. Étude de l'existant	6
1. Module de radiologie	6
2. Critique de l'existant.....	7
III. Cahier des charges.....	7
1. Contexte du projet	7
2. Objectifs	8
3. Besoins	9
4. Contraintes	9
5. Planning d'exécution.....	10
CHAPITRE II : ÉTUDE DU PROJET	11
I. Cancer du sein.....	11
1. Anatomie du sein.....	11
2. Définition du cancer du sein	12
2.1 Adénocarcinomes in situ.....	13
2.2 Adénocarcinomes infiltrant.....	13
3. Mécanisme de prolifération.....	13
4. Pathologies mammaires liée au cancer du sein	14
4.1. Calcification	14
4.1.1. Macrocalcification.....	14

4.1.2. Microcalcification	15
4.2. Masse.....	15
4.2.1. Forme	15
4.2.2. Contours	15
4.2.3. Densité.....	16
5. Classification du cancer du sein	17
5.1. Stade du cancer	17
5.2. Grade du cancer.....	18
II. Réseaux de neurones	18
1. Présentation des réseaux de neurones	18
1.1. Définition d'un neurone formel	19
1.2. Formulation mathématique du neurone formel.....	20
1.2.1. Fonction de combinaison	20
1.2.2. Fonction d'activation	21
2. Types de réseaux de neurones.....	22
III. État de l'art.....	23
1. Approches de résolution.....	23
1.1. Détection d'objets	23
1.2. Augmentation des données	24
1.3. Segmentation.....	24
1.4. Biologie	24
1.5. Modèles préentraînés	25
2. Présentation de notre approche	25
DEUXIÈME PARTIE : ÉTUDE TECHNIQUE.....	26
CHAPITRE III : CONCEPTION DU MODULE DE VISION PAR ORDINATEUR.....	27
I. Réseaux de neurones convolutifs.....	27
1. Généralités.....	27
2. Architecture des RNCs.....	27
2.1. Filtres.....	28
2.2. Opérations	28
2.2.1. Rembourrage	28
2.2.2. Foulée.....	29
2.2.3. Convolution.....	30
2.2.4. Mise en commun	31
2.3. Couches	31
2.3.1. Couche de convolution.....	31
2.3.2. Couche de mise en commun	32
2.3.3. Couche entièrement connectée.....	33
2.3.4. Couche de sortie.....	33

2.4. Types de propagations.....	33
2.4.1. Propagation en avant.....	33
2.4.1. Propagation en arrière	34
2.5. Algorithme succinct de l’entraînement d’un RNC.....	34
II. Modèle de Vision par ordinateur.....	35
1. Collecte et traitement de données	36
1.1. Collecte de données.....	36
1.2. Traitement de données	36
1.2.1. Exploration de données	37
1.2.2. Prétraitement des données.....	38
1.2.2.1. Conversion des images.....	38
1.2.2.2. Extraction de la zone d’intérêt	39
1.2.2.3. Normalisation et redimensionnement des images.....	39
1.2.2.4. Scinder notre ensemble de données	40
1.2.2.5. Augmentation des images	41
2. Construction du modèle de détection du cancer du sein	42
2.1. Modèles préentraînés	43
2.2. Couche d’auto attention	45
3. Évaluation et optimisation du modèle.....	46
3.1. Évaluation	46
3.1.1. Matrice de confusion.....	46
3.1.1.1. Métriques du rapport de classification	48
3.1.1.2. Rapport de classification	49
3.1.1.3. Grad-CAM	50
3.2. Optimisation des performances du modèle	52
CHAPITRE IV : ÉTUDE CONCEPTUELLE DE L’APPLICATION WEB ...	53
I. Choix de la méthode de conception.....	53
1. Étude comparative.....	53
2. Choix de la méthode de conception	54
II. Identification des acteurs et besoins du système	54
1. Présentation du langage de UML.....	54
2. Identification des acteurs du système.....	55
3. Identification des besoins du système	55
3.1. Diagramme de cas d’utilisation.....	55
3.2. Diagramme de séquence	58
3.3. Diagramme des classes	60
TROISIÈME PARTIE : RÉSULTATS ET DISCUSSION	61
CHAPITRE V : RÉSULTATS.....	62
I. Outils de développement	62

1. Environnement de travail	62
1.1. Matériel utilisé	62
1.2. Prérequis logiciel.....	62
1.2.1. Système d'exploitation (MacOs).....	62
1.2.2. Éditeur de code.....	63
2. Outils et technologies utilisés.....	63
2.1. Langage de développement.....	64
2.2. Librairie.....	64
2.3. Base de données	65
II. Présentation des résultats.....	65
1. Application web	65
1.1. Page de connexion.....	66
1.2. Page d'accueil	66
1.3. Page de diagnostic par la VO	67
1.4. Page de diagnostic du radiologue.....	67
2. Modèle de VO	69
CHAPITRE VI : DISCUSSION DES RÉSULTATS ET COÛT DU PROJET	71
I. Discussion des résultats	71
II. Coût du projet	71
CONCLUSION	72
BIBLIOGRAPHIE	xi
ANNEXE	xiv
Annexe A : Cancer du sein.....	xiv
Annexe B : Vision par ordinateur	xvi
Annexe C : Méthode et langage de modélisation.....	xxi

RÉSUMÉ

La finalité de ce travail est de concevoir un système d'aide à la détection du cancer du sein intégré dans un ERP, facilitant ainsi la détection des tumeurs à partir d'images de mammographies et contribuant à l'amélioration des soins de santé et à la recherche médicale. Nous avons utilisé des modèles pré-entraînés basés sur des réseaux de neurones convolutifs pour la détection du cancer du sein, en ajoutant des couches d'auto-attention, une carte d'activation de classe pondérée par le gradient et des techniques d'augmentations pour améliorer la performance du système. Nous avons démontré que notre solution offre des performances supérieures à 80% pour un taux de faux positifs supérieur à 20% sur un jeu de données de mammographies, composé de 1250 images, dont 291 images cancéreuses et 959 images saines. Les résultats obtenus sont prometteurs et montrent que notre approche est efficace pour la détection du cancer du sein. Ils ouvrent des perspectives intéressantes pour l'amélioration des soins de santé et le dépistage précoce du cancer du sein.

ABSTRACT

The aim of this work is to design an ERP-integrated breast cancer detection support system, facilitating tumor detection from mammogram images and contributing to improved healthcare and medical research. We used pre-trained models based on convolutional neural networks for breast cancer detection, adding layers of self-attention, a gradient-weighted class activation map and augmentation techniques to improve system performance. We have demonstrated that our solution delivers performance in excess of 80% for a false positive rate of over 20% on a mammography dataset consisting of 1250 images, including 291 cancerous images and 959 healthy images. These promising results show that our approach is effective in detecting breast cancer. They open up interesting prospects for improving healthcare and the early detection of breast cancer.